

Colégio Ítaca

Francisco Pessoa

Por que privacidade?
A proteção de dados pessoais num mundo conectado

Professor Orientador
João Homero do Amaral

São Paulo
2025

Sumário

Lista de Figuras	2
1 Os olhos que tudo vêem: caracterizando a coleta de dados	3
1.1 Características técnicas da vigilância	4
1.2 Os indivíduos sob os olhos da vigilância	6
1.3 Vigilância política	8
2 Título provisório do segundo capítulo	13
2.1 Regressões Lineares	14
2.2 Redes Neurais	17
2.3 O Mundo Real	21
2.4 Natureza	24
Referências	25

Lista de Figuras

2.1	Gráfico da anomalia (°C) em função do tempo (anos), 1970-2025	14
2.2	Gráfico da anomalia (°C) em função do tempo (anos), 1970-2025, com modelo de regressão linear	15
2.3	Gráfico da anomalia (°C) em função do tempo (anos), 1970-2025, com regressão linear e aproximação polinomial	16
2.4	Algumas imagens do banco de dados MNIST	18
2.5	Arquitetura de uma rede neural básica	19
2.6	Algumas das funções de ativação mais comuns, representadas no intervalo $[0, 1]$. Em laranja e vermelho, duas sigmóides com $k = 5$ e $k = 10$, respectivamente. Em preto, subposta ao segmento verde, a ReLU, e, em verde, a função degrau. .	21

Capítulo 1

Os olhos que tudo vêem: caracterizando a coleta de dados

A coisa seguia fazendo o que tinha que fazer, independentemente do que ele quisesse. Registrava minúsculas diferenças ao redor dele, uma ligeira alteração na umidade, uma fração de decréscimo na temperatura, o progresso de um inseto no teto da tendestiladora, a aproximação solene do amanhecer no trecho estrelado do céu que ele enxergava pelo lado transparente da tenda.

—Frank Herbert, *Duna*

Conforme a Pesquisa Nacional por Amostra em Domicílios (PNAD Contínua, realizada pelo Instituto Brasileiro de Geografia e Estatística), em 2023, 92,5% das casas brasileiras tinham acesso à Internet. O folheto no qual o dado foi divulgado considera que “apesar do aumento consistente desde o início da série histórica, essa taxa de crescimento tem sido cada vez menor, o que conversa com a aproximação desse número à universalização da Internet nos domicílios brasileiros” (PNAD Contínua, 2024, p.6). Assim, mais do que nunca, a população brasileira está integrada em serviços online – serviços esses que têm como uma de suas funções coletar quantidades massivas de dados pessoais.

Segundo Vopson (2020), a cada ano, são gerados aproximadamente 7,3 *zettabytes* de dados, isto é, $7,3 \times 10^{21}$ *bytes*¹. Essa quantidade estrondosa de informação não é constituída só de vídeos, textos, imagens, entre outros; a título de referência, o *Internet Archive*, organização sem fins lucrativos que busca arquivar todo o conteúdo publicamente disponível, tem um acervo na ordem dos *petabytes*, ou seja, 10^{15} *bytes* (Internet Archive, 2025). Isto é, esse acervo, que busca salvaguardar todos os livros, *sites*, filmes, seriados e documentos em livre acesso, inclusive compreendendo sites que estão hoje fora do ar, tem tamanho equivalente a 0,0001% ou um milionésimo dos dados gerados *por ano*.

Na verdade, o resto desse volume gigantesco é, em sua maioria, composto por registros cotidianos, resultados da interação rotineira dos usuários com serviços *online*. Eles são visualizações, *likes*, trajetos de mobilidade, ingressos, compras, saldos, histórico de buscas, entre

¹Um *byte* é formado por oito *bits* – oito “uns ou zeros” – e é considerado a menor unidade de informação para um computador.

muitos outros (Cyphers; Gebhart, 2019). Esses dados não são individualmente importantes; só adquirem significado no conjunto, na criação de um *perfil de comportamento* individual. Youyou, Kosinski e Stillwell (2015) demonstraram que, tomando como base informações aparentemente inofensivas – amizades do *Facebook* – é possível criar modelos computacionais que fazem previsões melhores, ou seja, sabem mais sobre o comportamento de uma pessoa do que parentes e amigos próximos. De modo similar, infere-se posicionamento político, localização, hábitos de consumo, interesses midiáticos e outra multitude de características pessoais extremamente valiosas partindo desses dados. O modo de funcionamento desses modelos é tratado no capítulo 2 deste texto.

Esses dados estão na mão, principalmente, das grandes empresas de tecnologia responsáveis pela maioria do tráfego na Internet. Ainda segundo Cyphers e Gebhart (2019, p. 23), a Google rastreia por volta de 80% de todas as transações na rede. Isto é, fica sabendo de 4 a cada 5 requisições. Atrás dela figuram outras grandes empresas como Facebook, Yandex (russa), Amazon, Microsoft e Adobe. Isto não implica necessariamente em tráfego direto: não são 80% das solicitações que acontecem em domínios ² da Google; contudo, em alguma etapa do processo, a Google estará envolvida. Na maior parte do tempo, isso ocorre indiretamente, por meio de anúncios e *iframes*³, partes de um site que são provenientes de outro servidor.

1.1 Características técnicas da vigilância

Para entender como ocorre esse rastreamento, será utilizado um exemplo anedótico que condensa algumas das práticas comuns. Utilizando as ferramentas de desenvolvedor do navegador, é possível obter um registro de todas as requisições feitas quando o usuário entra em um site, como um arquivo HAR ⁴. Um arquivo desse tipo gerado em www.uol.com ⁵, revela que simplesmente carregar a página inicial da UOL (um famoso portal de notícias brasileiro) implica em pelo menos 500 requisições. O grande problema, contudo, está no fato de que a maioria delas não é diretamente feita para www.uol.com e seus subdomínios, mas sim, puxam códigos e

²Um domínio é um nome de site na internet, em posse de uma pessoa ou organização. Por exemplo, o Instagram é dono do domínio instagram.com, e a USP, de usp.br. De um único domínio podem surgir subdomínios, como jornal.usp.br

³Um *iframe* é uma maneira de incluir o conteúdo visual de um site em outro, embutindo-o. É frequentemente utilizado para incluir postagens de redes sociais em notícias, por exemplo. Deste modo, ao invés de uma imagem estática abre-se a possibilidade de interação diretamente do site continente. Funcionam como uma caixa, dentro da qual o conteúdo de um site será mostrado.

⁴“Acervo HTTP”, do inglês “HTTP Archive”. Essencialmente, é uma grande lista de requisições HTTP feitas por um site, onde HTTP é o protocolo de transferência por trás da Internet.

⁵Esses dados foram capturados no dia 16 de maio de 2025, às 15h. O agente de usuário (conjunto de informações sobre si mesmo que o navegador manda para o servidor do qual quer requerir informações) do computador era “*Mozilla/5.0 (X11; Linux x86_64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/136.0.0.0 Safari/537.36*”. Esse experimento pode ser facilmente reproduzido em qualquer navegador, desde que o mesmo não inclua nenhuma medida de bloqueio de anúncios ou rastreadores. Basta entrar na aba de “Inspecionar”, na aba de Rede/Tráfego, e fazer uma captura.

informações de outros lugares – outros domínios. Entre eles, nesse exemplo, figuravam muitos domínios da Google, incluindo o Google Analytics, ferramenta que serve para registrar as ações feitas pelo usuário na página, como entrar em uma notícia, clicar num anúncio, fazer uma pesquisa, entre outros. Em decorrência disso, atos simples, como mover o cursor, já elevam esse total: esse sistema registra todas as interações que puder. Após 10 minutos com a página parada, a conta já tinha passado das 1100 requisições. Isso não é uma peculiaridade da UOL, mas sim, um conjunto de práticas muito comuns que acontecem em quase todos os sites monetizados, ou seja, que tiram algum dinheiro das visitas.

Pode parecer estranho que, ao entrar no UOL, o computador envie dados para um terceiro. O mecanismo por trás disso é que a UOL propositalmente embute pedaços de código alheios, os chamados Kits de Desenvolvimento de Software (SDKs, do inglês *software development kit*), que tomam controle parcial do tráfego da página. Os SDKs são utilizados para incluir serviços de terceiros, e podem tanto ser absolutamente necessários, como para garantir autenticação de usuários ou uma funcionalidade de pagamento, quanto para outros fins, como rastrear o comportamento de quem visita a página. Eles geralmente tomam o formato de um grande arquivo de código compactado, feito não para ser legível, mas sim rápido de carregar e executar. Esse obscurantismo tem outro efeito além de diminuir o tamanho do arquivo: ele acaba por, ainda que não intencionalmente, dificultar a análise do seu conteúdo.

SDKs são muito usados para carregar anúncios. Assim, ao invés de cada site tomar para si o trabalho de encontrar anunciantes, essa função é delegada para um serviço especializado, como o Google Ads. Em troca, obtém-se dinheiro pelos anúncios e dados das interações com a página, a fim de saber quantos usuários clicaram em cada reportagem, se passaram um bom tempo lendo, entre outros – tudo a fim de otimizar a monetização.

Uma ferramenta de monitoramento comumente utilizada são os chamados *tracking pixels*, pequenos pontos da tela, invisíveis e indiferenciáveis, que acompanham movimentações do cursor. Eles são registrados como um elemento da página, ganhando assim o privilégio de obter uma série de informações, mesmo sem que o usuário interaja com eles. Seu uso é comum também em e-mails (Kelion, 2021). Outros sistemas de captura de dados não precisam reservar um pedaço da tela, ou seja, adquirir uma aparência física: é perfeitamente possível que esse rastreamento seja feito completamente por “debaixo dos panos”, na forma de códigos que rodam paralelamente, em plano de fundo, sem interferir em nada na experiência principal da página.

Nesses casos, ainda é possível perceber que esse tipo de vigilância ocorre por meio da interceptação de requisições, como foi feito aqui com a UOL. Com essa técnica, um grupo de pesquisa internacional formado por acadêmicos do instituto espanhol IMDEA, da Universidade Católica da Lovaina (KU Leuven, na Bélgica) e da Universidade Radboud de Nimega (na Holanda) descobriu que a Meta, empresa por trás do Instagram e do Facebook, abusava de uma vulnerabilidade de segurança no sistema operacional Android para coletar o histórico de navegação dos usuários, até passando por cima de recursos de segurança como a “guia anônima”. Essa funcionalidade estava escondida no Meta Pixel, um SDK de monitoramento, sem que os

sites que usufruíam desse sistema soubessem. O Meta Pixel foi desativado depois dessa descoberta (Girish *et al.*, 2025; Teixeira, 2025).

Outra prática que acontece no UOL, mas que também é amplamente difundida em outras páginas, é a do *leilão de anúncios em tempo real*. Isso é uma prática organizada que determina qual anúncio mostrar para um usuário que acessa aquele serviço, por meio de um leilão que dura poucos milissegundos. Os anunciantes dão seus lances baseados em pacotes de dados do usuário-alvo que o *site* (chamado de *supply side platform* ou SSP, a plataforma de oferta) distribui. O maior lance (dado pela *demand side platform* ou DSP, a plataforma de demanda) ganha o espaço para disponibilizar seu anúncio. Nesse meio tempo, esses dados já foram distribuídos para muitos potenciais clientes, que não necessariamente fizeram um lance. Pode ocorrer que um dos participantes do leilão nem sequer tenha interesse em vender um anúncio, sempre dando lances inviáveis e se aproveitando disso para coletá-los. Há amplos problemas éticos com esse sistema, que ocorre geralmente sem que os usuários saibam que seus dados estão sendo vendidos (Bashir, 2019): é a troca indiscriminada de informações pessoais por dinheiro como método de maximizar o lucro.

A monetização de dados não passa necessariamente pela venda de anúncios. Está se tornando cada vez mais comum o uso de perfis de direção por seguros de carros (McKinsey, 2016; Hill, 2024). Deste modo, o valor do seguro pode aumentar quando for entendido que o motorista dirige “perigosamente”, segundo uma definição de perigo arbitrária e não revelada para o cliente. Por meio da coleta de dados, o seguro consegue ter uma imagem compreensiva do motorista, e recalibrar-se nos moldes dessa imagem. Assim, o motorista se vê coibido a exibir um tipo de comportamento, e forçado a dar para um terceiro um dado muito sensível: a localização em tempo real.

1.2 Os indivíduos sob os olhos da vigilância

Essa capacidade de caracterização – traçar um perfil comportamental de alguém baseado em suas interações cotidianas – é onde reside o perigo dessa vigilância. Ela trata o ser humano como um modelo fechado, previsível. Ademais, esses modelos, principalmente aqueles treinados com maiores quantidades de informação, são excelentes nessa tarefa, de modo que resultam em perfis acurados e ricos em detalhes. Isso pode ser usado para, por exemplo, desencorajar mulheres que buscam aborto com propaganda direcionada (Coutts, 2016), algo que só é possível pois algoritmos de classificação conseguiram identificar essas pessoas em específico dentre o universo de indivíduos.

É frequentemente dito que a Internet é um espaço anônimo, de modo que o que é feito nela é dificilmente ligado de volta a um indivíduo físico. Contudo, existe um grande problema com essa abordagem: mesmo sem as informações que podem identificar alguém – endereço,

número de identidade, conta bancária, que geralmente são mais contempladas em leis de proteção e privacidade, tornando sua aquisição e uso mais complicado – elas podem ser facilmente deduzidas, quando necessário. Os padrões de deslocamento, obtidos por aplicativos de GPS como o Google Maps, Waze e Moovit podem informar, com alguma precisão, o bairro, a rua, e até mesmo a casa onde alguém mora. Pesquisas por produtos em sites de comércio eletrônico dão base para a dedução de hábitos de consumo e renda.

Essas informações precisam ser unificadas, isto é, que várias fontes de dados converseem entre si, para construir um perfil único e mais completo. Isso requer diferenciar os usuários, algo que pode ser feito por qualquer tipo de identificação imutável do dispositivo em que esse acesso está sendo feito. Por exemplo, são usados aqui o número de IP ⁶, endereço MAC ⁷, os identificadores para anúncios providenciados pelo sistema operacional ⁸ e, ocasionalmente, um conjunto de informações enviadas pelo navegador no cabeçalho da requisição, algo conhecido como *impressão digital de navegador*, do inglês *browser fingerprinting* (Ohm, 2009; Chen, 2019). Outras técnicas de identificação incluem registrar chaves criptográficas (Sy *et al.*, 2018) e obter nomes de redes de WiFi (Binder, 2019). Voltando ao exemplo anterior do Meta Pixel, as informações do histórico obtidas por meio da vulnerabilidade eram cruzadas com outras por meio do endereço de IP, de modo que Meta não só tinha essa informação, como também alguém a quem ela pertencia. Detalhes dessas e mais técnicas podem ser encontrados em Cyphers e Gebhart (2019).

Fundamentalmente, essa situação é um problema de confiança. Podemos confiar em empresas que sabem de nossa personalidade e hábitos a fundo? Se ainda não ficou claro pelos exemplos anteriores, não: dentro da coleta de dados opera suprema a lógica do capital, do lucro; sempre buscando novos mercados onde se expandir. É por isso que são tão debatidas regulamentações legais do rastreo digital, algo que será melhor explorado no capítulo 3. Por ora, basta entender que a coleta de dados tem como objetivo primeiro o lucro e depois o interesse dos seus usuários: é necessário se preocupar com serviços vendendo localização em tempo real (Mackey, 2019), com informações de crianças sendo usadas para treinar Inteligências Artificiais ⁹ (doravante, IAs) (Schurig; Spagnuolo, 2024), e com empresas rastreando as lojas que um consumidor frequenta (Soltani, 2015), além dos já citados problemas com seguros de carro, pois essas atividades são *extremamente lucrativas*.

Em 2021, a ViaQuatro, operadora privada da Linha 4 - Amarela do metrô de São Paulo, foi multada por coleta ilegal de dados. O Instituto de Defesa do Consumidor (Idec), que pro-

⁶O endereço de Protocolo de Internet (do inglês *Internet Protocol address*) é um identificador de dispositivo dado a ele pela operadora de Internet. Geralmente, é dado só um IP para o roteador, que serve para todos que estejam nele. É uma informação de fácil obtenção, pois qualquer conexão entre dois computadores envolve a troca de seus respectivos IPs. Os endereços de IP são controlados pelo provedor de Internet, e mudam ocasionalmente.

⁷O número de Controle de Acesso ao Meio (do inglês *Medium Access Control address*) de modo similar ao IP, é também utilizado para estabelecer a conexão entre dois computadores. Contudo, o endereço MAC vem embutido no dispositivo, e só é utilizado para conexões a cabo, sendo de mais difícil obtenção.

⁸Tal qual o “Android Ad ID” e o “Apple IDFA”.

⁹As Inteligências Artificiais serão expandidas no segundo capítulo. Por enquanto, é suficiente entender que são um tipo de algoritmo que precisa ser treinado, processo que necessita de uma grande quantidade de dados.

tocolou o processo, alegava uso indevido da tecnologia de reconhecimento facial por meio de câmeras embutidas nas portas de plataforma que filmavam a reação dos passageiros quando expostos a anúncios. Concomitantemente, o sistema também estimaria gênero e idade. (Soprana; Amâncio, 2021). Isso é, de maneira muito clara, uma tentativa de otimizar o serviço de propaganda. A *otimização* é um fator muito importante aqui – é, novamente, um tratamento matemático das relações humanas, de modo que a compra torna-se uma função que se deve maximizar.

1.3 Vigilância política

Os exemplos colocados aqui são principalmente relacionados às empresas estadunidenses, ou pelo menos ao que podemos hoje considerar um bloco tecnológico-econômico ocidental. Não é possível falar disso sem mencionar a questão territorial: muitos desses serviços e produtos são provenientes do chamado “Vale do Silício”, e compartilham filosofias semelhantes. São essenciais os processos históricos que aconteceram concomitantes ao surgimento da Internet, principalmente, a instauração do neoliberalismo como sistema econômico hegemônico. Para o economista bielorrusso Evgeny Morozov, em seu ensaio “Capitalismo Tecnológico e Cidadania”, a retórica do Vale do Silício se espalhou globalmente graças ao “triunfo da ideologia neoliberal subsequente à Guerra Fria que suprimiu com êxito os aspectos não econômicos da nossa existência social, fazendo com que a identidade de consumidor sobrepujasse a de cidadão” (Morozov, 2018, p. 19). Não dá para dizer que a coleta de dados não seja praticada na Rússia ou na China – ela é ubíqua mesmo dentro desses países – mas é possível dizer que os mecanismos sociais de vigilância são inseparáveis da realidade econômica dos países onde acontecem.

Ainda segundo Morozov (2018, p. 15),

Não há como responder a tais questões sem antes admitir a presença do elefante na sala do servidor: as nossas tecnologias - e as ideologias que elas promovem - são, em grande medida, norte-americanas. É bem verdade que as empresas russas e chinesas têm fortalecido cada vez mais a sua musculatura, tanto em casa como no exterior. Não há como negar, porém, que os governos desses países se opõem mais ao imperialismo de Washington do que ao neoliberalismo do Vale do Silício. O que eles mais temem é o uso geopolítico das plataformas estrangeiras de tecnologia contra seus interesses nacionais; mas não veem muito problema no modelo básico hipercapitalista de plataforma/monopólio adotado por muitas empresas do Vale do Silício.

Essa tal “retórica do Vale do Silício” trata-se principalmente de uma promessa de emancipação: tal como a Uber, que promete a seus usuários liberdade na mobilidade, ou mesmo as redes sociais, que prometem liberdade de expressão. Ela é cuidadosamente feita para se passar por *anti-establishment*; a Uber contra os taxistas, as redes sociais contra a grande mídia, a Airbnb

contra os hotéis. Contudo, é precisamente por meio dessa aparência ‘do contra’ que o Vale do Silício consolidou novos monopólios, passou por cima de regulações trabalhistas existentes (e, assim, precarizou o trabalho), e, explorando o que por muito tempo foi uma terra-sem-lei de regulações – o mundo digital – impôs a vigilância como modelo básico de funcionamento. É importante entender, pois, que ela constitui um discurso ideologicamente carregado, que normatiza uma ordem social específica – a vigilância.

Essa vigilância opera como uma alienação de alguns aspectos da vida humana, que são terceirizados para esses algoritmos, de modo que ocorre uma aproximação entre modo de vida e o lucro. Assim, cada ínfimo detalhe pode ajudar a monetizar mais um serviço, que – por meios imorais e frequentemente danosos – otimiza-se para extrair o máximo de dinheiro possível. Segundo Mejias e Couldry (2024), ocorre uma aproximação entre a *cognição* (processo de adquirir o saber, aqui caracterizado como a coleta e uso de dados) e a *economia* (processo de lucro), que provocou o surgimento de uma infraestrutura visando o processamento de dados por meio do que chamam de setor econômico de quantificação social.

É importante ressaltar isso – foi construída uma *infraestrutura de vigilância*. É mais do que algo local, que acontece só com um site ou outro: trata-se de uma profunda transformação socioeconômica que apropria-se da vida humana para a geração de dados. As redes sociais, as tais “plataformas digitais”, são baseadas em atividades que já existiam; falar (Twitter e Facebook), fotografar (Instagram), encontrar emprego (Linkedin), comer (Ifood), e até paquerar (Tinder). Diferenciam-se dos antigos métodos de realizar essas mesmas atividades, pois agora coletam dados e otimizam seus serviços para o lucro por meio deles.

Essa abordagem, para o que se propõe, é ótima; os modelos treinados por meio de quantidades massivas de dados são muito bons no que fazem, como já foi dito. Tão boa que nem mesmo a política institucional escapou dela, e cada vez mais as eleições são pautadas pela capacidade de utilizar-se dessas plataformas. E para essas plataformas, não importa a veracidade nem a moral de uma notícia: por exemplo, as *fake news* nada mais são do que notícias otimizadas, que dão mais dinheiro. Concilia-se essa enorme contradição interna pois, independentemente do que é publicado, o dinheiro dos anúncios continua fluindo (Morozov, 2018).

Voltando à ilusão da Internet como um espaço anônimo, é comum dizer que aqueles que não têm nada a esconder não deveriam se preocupar com privacidade. O problema com essa abordagem é que privacidade não se trata de segredos a serem escondidos, assim como um cofre guarda seus conteúdos. O problema da privacidade, tal como ele é posto agora, é muito mais ardiloso do que isso. Quando tantas relações sociais estão “plataformizadas” – isto é, passíveis à acumulação de dados –, e em plataformas que respondem também a uma lógica capitalista de lucro, tendendo ao monopólio, o mundo digital deixa de ser democrático, livre, e se torna sujeito à influência, por meio dos algoritmos. Hoje, muitos formam opiniões, adquirem produtos e mudam suas rotinas motivados (ainda que parcialmente) pelo que viram, ouviram e leram no plano digital.

Seria ingênuo pensar que essas plataformas são neutras, e atuam puramente como inter-

mediárias. Elas têm interesses políticos concretos, e, com tantos dados e saber sobre a vida das pessoas, ampla influência também. Em 30 de maio de 2025, o Partido Liberal (PL), entre cujos filiados figura o ex-presidente Jair Bolsonaro, organizou um grande seminário sobre tecnologia, com participação de altos executivos de grandes empresas de tecnologia como Google e Meta. Segundo Sérgio de Souza, repórter do Intercept que cobriu o evento,

A mensagem era clara: as big techs estavam ali em peso, abençoando o evento e compartilhando com os participantes o “caminho das pedras” para usar suas ferramentas mais novas e poderosas.

Essa relação de proximidade foi reforçada por Bolsonaro, que discursou no encerramento do encontro, aos gritos de “volta, capitão” vindos da plateia. O ex-presidente não deixou dúvidas ao afirmar que as empresas de tecnologia estavam “do lado certo”. (De Souza, 2025)

Elas não estavam ali por acaso: vigiar é um ato profundamente político, que está entre as bases da sociedade moderna. O filósofo Byung-Chul Han propõe que o antigo regime disciplinar na base do capitalismo industrial, agora se transformou em um regime baseado em informação.

O capitalismo da informação, assentado sobre a comunicação e a conexão, torna obsoletas técnicas disciplinares como a isolamento [*sic*] espacial, a regulamentação rigorosa do trabalho ou o adestramento corporal. A “docilidade” (*Gelehrigkeit*, a capacidade de aprender, como em alemão se traduziu o termo francês *docilité*), que significa também obediência ou ductilidade, não é o ideal do regime da informação. O sujeito submisso do regime de informação não é nem dócil, nem obediente. Ao contrário, supõe-se livre, autêntico e criativo. Produz-se e se performa.

[...]

A dominação do regime de informação é ocultada, na medida em que se funde completamente com o cotidiano. É encoberta atrás da complacência das mídias sociais, da comodidade das máquinas de busca, das vozes embalantes das assistentes de voz ou da oficiosidade prestativa dos smart apps, os aplicativos inteligentes. O smartphone se revela como um informante eficiente, que nos submete a uma vigilância duradoura. [...] A vigilância infiltra-se no cotidiano na forma da conveniência. No presídio digital como zona de bem-estar smart não se ergue nenhuma oposição contra o regime dominante. O Like exclui toda revolução. (Han, 2022, p. 8-16)

Han não é o único teórico que propõe que uma nova configuração do velho capitalismo está emergindo. Alguns, inclusive, elencam um pós-capitalismo, chegando à ideia de tecnofeudalismo (Varoufakis, 2023). Outros criticam essa elaboração, entendendo que há apenas uma continuação do sistema já existente (Morozov; Denvir, 2023). Contudo, todos concordam que as tecnologias digitais estão provocando amplas transformações na nossa organização social e reorganizações produtivas.

Essas transformações já chegaram no Brasil: afora o congresso do PL já mencionado, nota-se o imenso embróglio político que acontece com as propostas de regulamentação de IAs e redes sociais no Legislativo, onde as grandes empresas de tecnologia exerceram muita pressão

(Schurig; Granjeia, 2024; Schurig; Almeida, 2024). Para o jornalista Sérgio Spagnuolo, “O lobby das Big Techs venceu no Brasil”, de modo que as propostas que tinham potencial de as prejudicar, como o PL 2630/2020, foram engavetadas (Spagnuolo, 2024).

O Conselho Digital (<https://conselhodigital.org.br/>), entidade constituída por Amazon, Discord, Google, Hotmart, Kwai, Meta, TikTok e Uber é um dos expoentes disso. As mesmas empresas que vigiam cada passo dado por seus usuários estão gastando muito dinheiro, fazendo um “lobby descarado” (De Toledo, 2023), para garantir que projetos de lei onerosos a eles não sejam aprovados. Chegaram ao ponto de até contratar o ex-presidente Michel Temer para atuar nas negociações (Mello, 2023).

Não é só no Brasil que isso acontece: na Nigéria, outro país não desenvolvido, ocorre um caso semelhante: a Meta não se contentou com as regulamentações propostas, e ameaça sair do país após receber uma multa milionária (Asadu, 2024).

É importante reiterar que, hoje em dia, *dados representam poder*: poder político, econômico, e social. Ele permite uma maximização do lucro, efetivando uma subjugação dos processos sociais aos interesses financeiros de grandes corporações.

Um dos exemplos mais emblemáticos do uso de dados na política foi o caso da Cambridge Analytica, uma firma que realizava consultoria para campanhas publicitárias. Por meio de dados de perfis do Facebook, que eles obtiveram por meio das ferramentas públicas do próprio Facebook, conseguiram criar perfis psicológicos de 50 milhões de usuários da plataforma e, assim, os servir anúncios especificamente criados para manipulá-los do jeito mais efetivo. Com essa prática, chamada de anúncios escuros (do inglês *dark ads*), uma publicidade será mostrada somente para aqueles que estão mais suscetíveis a ela, sendo praticamente invisível para o resto da sociedade. A Cambridge Analytica foi parte integral da campanha eleitoral de Donald Trump em 2016, e dos partidários da saída do Reino Unido da União Europeia durante o Brexit. Em ambos os casos, foi vitoriosa (Cadwalladr; Graham-Harrison, 2018).

Por que é possível fazer isso? Como até uma empresa de fora do Facebook consegue obter dados suficientes para fazer uma campanha tão destrutiva? O caso da Cambridge Analytica ilustra alguns pontos bastante importantes. Primeiro que é possível, por meio dos dados, criar modelos que descrevem com acurácia um eleitor, e, sem seu consentimento, manipulá-lo. Quando marqueteiros falam de *taxa de conversão* de um anúncio, poderiam muito bem estar falando da conversão de um voto. Segundo Christopher Wylie, ex-funcionário da Cambridge Analytica, “Nós exploramos o Facebook para colher os perfis de milhões de pessoas. E construímos modelos para explorar o que já sabíamos sobre elas e atingir seus demônios interiores. Essa foi a base sobre a qual a empresa inteira foi construída.” (Cadwalladr; Graham-Harrison, 2018, tradução própria)¹⁰

Segundo, que é possível e perfeitamente viável manipular eleições inteiras por meio dessas tecnologias, outorgando poder gigantesco àqueles que tiverem dinheiro para pagar por essas

¹⁰No original, “We exploited Facebook to harvest millions of people’s profiles. And built models to exploit what we knew about them and target their inner demons. That was the basis the entire company was built on.”

campanhas. Tudo com conivência (ou, no mínimo, leniência) das grandes corporações de tecnologia. E não precisa ser só em eleições: em 2018, uma investigação da ONU acusou o Facebook de ter tido um papel determinante no genocídio de mais de setecentos mil rohingyas muçulmanos no Myanmar (Barron, 2018). O discurso de ódio, aos olhos do algoritmo de uma rede social, é só mais conteúdo viralizando, independente de quão intolerante for. Ele dá dinheiro.

Capturar dados pessoais é um ato profundamente político. E os usos que se dão a eles cada vez mais englobam o funcionamento da sociedade inteira. Até agora, nesse texto, o algoritmo foi entendido como uma entidade elusiva e misteriosa, mas poderosa e influente. Trata-se da *maneira de processar* os dados coletados; o processo pelo qual as milhões de entradas em uma base de dados são transformadas em postagens recomendadas, anúncios, e tantas outras aplicações. O próximo capítulo, assim, será dedicado a destrinchá-lo, compreender seus mecanismos de funcionamento, e entender como as técnicas de tratamento de dados que hoje são empregadas podem influenciar nos resultados, a partir de uma visão pautada na privacidade e na transparência.

Capítulo 2

Título provisório do segundo capítulo

É difícil ver o noticiário hoje sem se deparar com as Inteligências Artificiais (IAs). Contudo, entre o uso de ChatGPT para trabalhos escolares, trabalhadores preocupados com perder o emprego para uma máquina, e até alguns com medo da humanidade ser inteiramente aniquilada num apocalipse da era digital, o uso de IAs é tão mais comum quanto mais dissimulado.

A culpa disso é do fato que “Inteligência Artificial” está muito mais próximo de uma expressão de marketing feita para atrair a atenção do que de um termo técnico. Ela pressupõe uma semelhança entre o pensamento orgânico, tal como humanos o fazem, e um suposto pensamento sintético que, como há de ser visto nesse capítulo, é inteiramente dessemelhante a seu equivalente vivo.

Por trás da Inteligência Artificial há um conjunto de técnicas estatísticas e computacionais que fazem o chamado *aprendizado de máquina* ou *aprendizado estatístico*. Antes de entender *como* um computador pode aprender, é necessário responder *por que* se quer que ele aprenda. Há muito que um computador pode fazer sem a necessidade desse treinamento: isso inclui fazer contas, navegar pela Internet, assistir a um filme, tipografar uma monografia, entre outros. Então, o que diferencia essas atividades de uma Inteligência Artificial?


A resposta é que essas atividades podem ser (e são) descritas por meio de código, o que requer representá-las como um conjunto de instruções claras e objetivas: uma receita de como as realizar. É fácil elaborar uma receita de como reproduzir um vídeo, por exemplo. O computador deverá localizar o arquivo que contém o vídeo, abri-lo, decodificá-lo e reproduzi-lo, convertendo as informações numéricas para cores a uma determinada taxa de vezes por segundo. Por mais que cada passo aqui descrito possa ser desmembrado em tantos outros mais, qualquer programa de computador é descritível como um conjunto de instruções. Todo processador é construído aos moldes de uma Arquitetura de Conjunto de Instruções (ISA, do inglês *Instruction Set Architecture*), um modelo abstrato que delimita, simplificadamente, como se pode programá-lo. Um dos componentes disso é um conjunto de instruções que o processador pode executar, para o qual *todos* os programas que são usados devem ser reduzidos. Essas instruções são coisas simples, como “coloque tal valor em tal lugar”, “some tal valor com tal valor” e “faça isso se tal valor for verdadeiro”.

É possível criar uma “receita para escrever”? Ou uma “receita para recomendar vídeos”? Isto é, um conjunto de instruções objetivas que permita realizar essas ações? Não. E é aqui que entra o uso de uma IA: aproximar objetivamente processos que não podem ser descritos assim.

2.1 Regressões Lineares

Observe o seguinte gráfico com o valor da anomalia da temperatura média do globo terrestre em relação à média do século XX, entre 1970 e 2025:

Figura 2.1: Gráfico da anomalia (°C) em função do tempo (anos), 1970-2025



Empiricamente, é possível perceber que existe uma tendência nesses dados, que seguem aproximadamente uma reta. Porém, é difícil determinar precisamente de quanto é essa tendência, e para onde o gráfico continuará. Isso se deve ao fato de que o planeta Terra é um sistema complexo: ele não segue uma ordem do tipo “aumente 0,5 °C ao ano”. Na metáfora da seção anterior, é impossível estabelecer uma receita para a temperatura do planeta em função do ano.

Pode-se, contudo, aproximá-la. Sabe-se, a partir desses dados, como o modelo deve se comportar. Não é possível, principalmente quando se trata de algo tão simples como uma reta, que ele abarque cada mínima mudança e inconsistência; é, afinal, uma aproximação.

Qual deverá ser a forma desse modelo? Matematicamente, uma reta pode ser definida por meio de uma função linear, que, nesse caso, assumiria a forma de

$$A(t) = t \cdot \beta_1 + \beta_0 \quad (2.1)$$

Isto é, a anomalia A , em função do tempo t , pode ser definida como o tempo t multiplicado por um coeficiente β_1 somado a um coeficiente estático β_0 . Assim, para determinar a anomalia, t deve ser transformado, segundo os parâmetros β_0 e β_1 que, até agora, *não se sabe quais são*. Intuitivamente, β_1 é a inclinação da reta e β_0 a altura dela. A grande pergunta, portanto, é quais são esses coeficientes, ou seja, como t deve ser mudado para obter A .


Para determinar esses dois coeficientes, β_0 e β_1 , é necessário primeiro conceber uma maneira de comparar dois modelos, e descobrir qual deles mais se aproxima do fenômeno apro-

ximado. Uma maneira muito simples de fazer isso é, para cada ano, contabilizar a distância entre o valor previsto pelo modelo e a observação real. O objetivo da criação do modelo, assim, passa a ser reduzir ao máximo possível esse erro. Comumente, ao invés de simplesmente usar o erro, é considerado o erro elevado ao quadrado; assim, erros menores são menos penalizados, e erros maiores serão ainda mais penalizados, pois seu valor crescerá com mais rapidez. Essa abordagem é chamada de “mínimos quadrados”, pois almeja minimizar os quadrados dos erros.

O processo de descobrir β_0 e β_1 é conhecido como *aprendizado* ou *treinamento*. Ele envolve inicializar esses valores com um “chute”, e, gradualmente, melhorá-los. Para isso, muda-se ou β_0 ou β_1 , incrementando-o por pouco. Se a mudança for bem-vinda, ou seja, diminuir o erro, ela é mantida; caso contrário, o original é melhor. Ao repetir esse processo várias vezes, a reta será acomodada nos coeficientes com menor valor de erro.

No caso da figura 2.1, isso toma a forma da figura 2.2.


Figura 2.2: Gráfico da anomalia (°C) em função do tempo (anos), 1970-2025, com modelo de regressão linear



Antes, foi dito que β_1 representava a inclinação da reta. Além disso, ele cumpre outra função importante: representar a *taxa de variação* da reta; como a unidade de medida em questão é anos, isso significa quanto a temperatura vai variar por ano. A regressão realizada nesse conjunto de dados revela que a anomalia de temperatura média global cresce em um ritmo de $0,01879^{\circ}\text{C}$ ao ano.

Perceptivelmente, essa anomalia vem crescendo mais nos últimos anos do que vinha anteriormente, devido às mudanças climáticas. O modelo de reta, por ter que simplificar drasticamente, é incapaz de expressar isso, de tal modo que nos últimos três anos sua estimativa está abaixo do valor real. Geralmente, o que importa não é o quão próximo o modelo está dos dados já existentes, mas sim o quão bem o modelo se dá com extrapolar esses dados e, literalmente, prever o futuro. Dadas essas tendências recentes, esse modelo pode não ser tão útil, uma vez que não detêm a habilidade de contemplá-las suficientemente. Um modelo melhor, nesse caso, ao invés de uma reta usaria uma curva. Um exemplo está na figura 2.3.

Figura 2.3: Gráfico da anomalia (°C) em função do tempo (anos), 1970-2025, com regressão linear e aproximação polinomial



Esse modelo não é mais linear, evidentemente. É, pelo contrário, uma curva definida por meio de um polinômio. Nesse caso, a representação matemática é de

$$A(t) = \beta_0 + t\beta_1 + t^2\beta_2 + t^3\beta_3 \dots t^n\beta_n \quad (2.2)$$

Onde n é o grau do polinômio a ser criado. Aqui, não se trata de uma regressão *linear*, mas sim, *polinomial*.

Está além do escopo deste presente texto debater o funcionamento interno desses modelos (isto é, como efetivamente ocorre a regressão linear), mas é importante perceber que, quando se utiliza uma curva, ao invés de uma reta, o modelo torna-se mais flexível, podendo adaptar-se melhor às condições dos dados. Isto é, o erro do modelo é menor. Contudo, ao invés de dois parâmetros simples – β_0 e β_1 – agora há n , que não podem ser compreendidos de uma maneira tão direta quanto esses dois. Isto é, ganha-se flexibilidade, mas há uma perda de interpretabilidade. Na próxima seção, 2.2, será estudado um modelo ainda mais flexível; e ainda menos interpretável: as redes neurais. A seção 2.3 debaterá como essa “interpretabilidade” é refletida em um caso real: é possível pedir explicações desses modelos? Isto é, determinar porque algo foi classificado como bom ou ruim, A ou B?

O exemplo aqui apresentado parece simples, mas serve para definir um conceito importante, que será retomado múltiplas vezes: o *aprendizado de máquina*. Para um computador, aprender é diminuir uma função erro, por meio da alteração de um conjunto de parâmetros. O aprendizado requer dados; muitos dados; e aí entra o conteúdo do primeiro capítulo. Terminado o treinamento, o modelo vai poder, a partir dos dados coletados, realizar previsões, inferências, classificações, entre outros, acerca desses dados.

Regressões lineares são um dos algoritmos mais simples que demonstram a dinâmica completa do aprendizado de máquina; tanto é, que foi o primeiro desses algoritmos a ser estudado, com o método de mínimos quadrados tendo sido empregado por Isaac Newton para deter-

minar a duração exata do ano (Belenkiy; Echague, 2016). Há diversas maneiras de melhorá-lo. Uma das mais simples é realizar a regressão em mais de uma variável; por exemplo, podemos estimar o preço de uma casa baseado no tamanho (em m²), o número de quartos, a distância do centro, o andar, e a idade da casa. O modelo se assemelharia à equação 2.3.

$$\text{Preço} = \beta_0 + \beta_1 \cdot (\text{Tamanho}) + \beta_2 \cdot (\text{Quartos}) + \beta_3 \cdot (\text{Distância}) + \beta_5 \cdot (\text{Andar}) + \beta_6 \cdot (\text{Idade}) \quad (2.3)$$

Onde $\beta_1, \beta_2, \beta_3, \beta_4, \beta_5$ e β_6 representam o quão significativos seus respectivos parâmetros são para o preço total do apartamento.

2.2 Redes Neurais

Por mais úteis que as regressões lineares possam ser, ainda são um modelo rudimentar, que trabalha com alguns pressupostos bastante restritivos. Um deles é o da linearidade da relação entre uma variável – como o ano, no caso da anomalia de temperatura, ou o andar, no caso do preço de apartamentos – e o resultado desejado. Assim, pressupõe-se que essa relação se dá por uma reta, e não, por exemplo, uma curva exponencial, logarítmica, ou qualquer outra coisa que fuja da linearidade. Viu-se que isso pode ser consertado por meio de uma regressão polinomial¹. Contudo, há ainda um problema maior que a impede de ser utilizada em mais contextos: a possibilidade de relações entre variáveis. Para entender o que isso significa, considere outro exemplo: o banco de dados MNIST (LeCun; Cortes; Burges, 1998).


Ele é composto por milhares de imagens de dígitos de 0-9 desenhados à mão, assim como na figura 2.4. O objetivo que ele apresenta é fazer um modelo computacional capaz de identificar os dígitos baseando-se nas imagens apresentadas, semelhante ao que um ser humano faria ao ler esses números. Por mais que isso pareça simples, esse problema não o é – as imagens variam muito em sua forma, e a computação demorou para desenvolver métodos flexíveis o suficiente para essa tarefa.

O banco de dados MNIST foi publicado em 1998, e, segundo o próprio autor, o recorde é de 0,23% de erro, atingido em 2012, dentre os resultados publicados na literatura (Cireşan; Meier; Schmidhuber, 2012). As primeiras tentativas resultaram em taxas por volta dos 12% (LeCun; Cortes; Burges, 1998).

Essas imagens são na resolução de 28x28, ou seja, são constituídas de 28 linhas e 28 colunas de píxeis. Cada píxel pode assumir um valor em escala de cinza, representado como

¹A regressão polinomial está associada a muitos outros métodos que a acompanham. Para estendê-la para uma predição com base em múltiplas variáveis, como na equação 2.3, por exemplo, é possível usar um Método Aditivo Generalizado (GAM). Os GAMs criam uma função polinomial de grau n para cada variável, ou seja, uma função para o tamanho, uma para o número de quartos, uma para a distância do centro, e por aí vai. Assim, o modelo toma a cara de $\text{Preço} = \beta_0 + f_1(X_1) + f_2(X_2) + f_3(X_3) + \dots + f_i(X_i)$, onde $X_1 \dots X_i$ são as variáveis (como o andar e o número de quartos) e $f_1 \dots f_i$ são as funções de grau n que dependem de cada variável (James *et al.*, 2021)

Figura 2.4: Algumas imagens do banco de dados MNIST



um número inteiro entre 0 (preto) e 255 (branco)². Isso significa que um modelo para prever o dígito escrito deve ter $28 \cdot 28 = 784$ entradas, e deve ter como saída um número inteiro entre 0 e 9.

A complicação aqui apresentada é que, como cada um desses valores é uma variável, não se quer mais analisar a relação de uma única variável com a saída – é inútil saber quanto um único píxel influencia na saída –, mas sim, é necessário considerar um *conjunto* de variáveis combinadas, como um traço ou uma curva. O modelo de regressões lineares, e mesmo as regressões polinomiais, não permitem isso, uma vez que tratam todas as variáveis de maneira independente.

Um dos métodos mais famosos para resolver tal problema são as redes neurais, que ganharam esse nome por seus componentes se assemelharem a neurônios. A arquitetura de uma rede neural básica está representada na figura 2.5.

Nesse modelo simples, há três camadas. A *camada de entrada* representa as variáveis sobre as quais se quer prever o resultado. Aqui, são três, E_1 , E_2 , e E_3 , mas outros modelos podem ser estruturados de modo a ter mais, ou menos. No caso do MNIST, é estritamente necessário que haja 784 nós de entrada, um para cada píxel da imagem.


No meio, temos uma *camada oculta*, que recebe esse nome, pois não é nem de entrada, nem de saída. Cada nó da camada oculta representa uma combinação de todos os nós da camada anterior, como se cada um deles fosse uma regressão linear feita na camada anterior. Por exemplo, o nó intermediário O_1 pode ser representado, a grosso modo, como:

$$O_1 = \beta_0 + \beta_1 \cdot E_1 + \beta_2 \cdot E_2 + \beta_3 \cdot E_3 \quad (2.4)$$

A *camada de saída* tem o mesmo princípio da camada oculta: cada nó dela é uma combinação de todos os nós da camada anterior (ou seja, os nós da camada oculta). A única diferença é que, no modelo já treinado, esses nós representam valores reais. Para o MNIST, isso geral-

²Se 255 parece um número arbitrário, lembre-se que ele é igual a $2^8 - 1$, o maior valor possível que pode ser guardado em oito bits

Figura 2.5: Arquitetura de uma rede neural básica



mente é modelado como dez nós, cada um representando um dígito diferente, de modo que o valor computado de um nó seja equivalente à probabilidade (ou confiança), de que o algoritmo certo seja aquele. Assim, o nó de maior valor será o dígito certo.

Contudo, o leitor astuto perceberá que nessa arquitetura é possível “simplificar” a rede neural, voltando a ser uma única função linear³. E isso é verdade. O pulo do gato, porém, é que a equação 2.4 só conta metade da história. A maneira certa de expressar o valor de um nó N em função de suas entradas (os nós da camada anterior que “apontam” para N) $I_1 \dots I_n$ é

$$N = \phi(\beta_0 + \beta_1 \cdot I_1 + \beta_2 \cdot I_2 + \dots + \beta_n \cdot I_n) \quad (2.5)$$

A única diferença da equação 2.5 para a equação 2.4 é a introdução de ϕ , uma função não-linear pré-determinada que atua como uma fonte de não linearidade para o modelo. Essa é a chamada *função de ativação*, e computa o valor de um nó da rede baseado em suas entradas e seus pesos (outro nome para os coeficientes que até agora foram chamados de β_n). Algumas funções de ativação comuns são a sigmoide⁴

$$\sigma(x) = \frac{1}{1 + e^{-kx}} \quad (2.6)$$

para uma dada constante k ; a retificadora linear ReLU

$$\text{ReLU}(x) = \max(0, x) \quad (2.7)$$

³Formalmente, a composição de várias funções lineares, que se dá por meio dos nós, ainda é uma função linear.

⁴EXPLICAR

e a função degrau, ou função de Heaviside,

$$H(x) = \begin{cases} 0 & x \leq 0 \\ 1 & x \geq 0 \end{cases} \quad (2.8)$$

A figura 2.6 mostra o comportamento delas.

A função dessas funções é introduzir a não-linearidade e, assim, permitir que se estabeleçam relações não-lineares entre as diversas entradas. Elas elevam a rede neural de uma simples “combinação de combinações lineares” para um modelo flexível capaz de expressar relações complexas.


Sendo assim, como se otimiza esses pesos? Com cálculo diferencial, principalmente. Computa-se um gradiente multidimensional que indica para onde vai o erro (aumentar ou diminuir) baseado em uma mudança num determinado parâmetro. Simplificadamente, para otimizar o parâmetro β_2 do nó X , “congela-se” o resto dos parâmetros e calcula-se o quanto o erro vai mudar baseado em uma mudança minúscula em β_2 . Na realidade, esse processo usa de vários métodos matemáticos, como diferenciação automática, descida de gradiente e retro-propagação. É muito elegante, mas foge ao escopo desse texto.

Uma rede neural têm muito mais parâmetros que uma regressão linear – como se havia dito, cada nó tem tantos pesos quanto entradas, e podem haver tantos nós quantos forem necessários. A arquitetura da imagem 2.5 é simplista também por representar somente uma camada oculta, quando na maioria dos casos se usam múltiplas, gerando ainda mais parâmetros. A expressão inglesa *Deep Learning* (aprendizado profundo) vem disso: uma rede neural é considerada profunda se tiver mais de uma camada oculta. Os grandes modelos de linguagem (LLMs) como o ChatGPT e o Deepseek, têm na ordem dos *bilhões* de parâmetros [CITAÇÃO NECESÁRIA]. O problema com isso é que se torna basicamente impossível entender individualmente o que um determinado parâmetro significa. A rede neural é sobretudo opaca, ininterpretável. Sendo ela uma aproximação dos dados, sabe-se que ela funciona, mas não *como* ela funciona, e, como uma aproximação, há sempre um erro.

Nessa miríade de métodos e funções, há muita margem para que um modelo que está certo (isto é, diminui a função erro ao máximo) errar: é possível, por exemplo, que haja demasiada precisão nas ínfimas características dos dados de treinamento, de modo que a taxa de erro diminui vertiginosamente (pois o modelo acompanha cada mínimo ruído dos dados) mas a capacidade de generalização se perde. Esse é um problema conhecido como *overfitting*. Ou também, é possível que o modelo entenda algum tipo de viés nos dados – como, por exemplo, haver mais dados de homens do que de mulheres – e enxergue uma relação disso com o resultado – por exemplo, achar que como mais brancos historicamente passam em vestibulares, logo brancos seriam mais capacitados para passar em vestibulares, tendo assim maior chance de aprovação. Um exemplo real desse problema será analisado na próxima seção, 2.3.

O leitor agora pode estar se perguntando por que os exemplos aqui utilizados não têm

Figura 2.6: Algumas das funções de ativação mais comuns, representadas no intervalo $[0, 1]$. Em laranja e vermelho, duas sigmóides com $k = 5$ e $k = 10$, respectivamente. Em preto, subposta ao segmento verde, a ReLU, e, em verde, a função degrau.



relação com o conteúdo do capítulo anterior. Afinal, para onde vão tantos dados coletados? A resposta é, para algoritmos muito parecidos com os apresentados, porém com quantidades de parâmetros e complexidade muito maiores. Um algoritmo de recomendação, por exemplo, tem de lidar com um fluxo enorme de dados concomitante. São tantos dados que esse segmento da indústria foi batizado de *Big Data* (literalmente, “Grande Dado”), concernindo os casos onde há uma vigilância tão presente, que produz uma massa de dados gigantesca; muito além do que pode ser tratado em um computador comum. Só os *Data Centers* especializados, que se estendem por múltiplos quilômetros quadrados e tem o consumo energético de cidades inteiras, podem manejar os tantos dados necessários para todos os múltiplos usuários simultâneos desses serviços. A era do Big Data é um tempo em que o conjunto de dados que um ser humano produz é alienado dele, passando para o uso quase livre das empresas de tecnologia que têm a infraestrutura necessária para o processar: as assim chamadas “Big Techs”, ou grandes empresas de tecnologia.

2.3 O Mundo Real

Deixe os grandes algoritmos de lado; considere agora um pequeno exemplo com grandes implicações. Desde 2014, a Amazon vinha tentando filtrar computacionalmente os currículos a ela enviados. Em 2018, contudo, essa iniciativa foi posta abaixo em completo. O motivo? O algoritmo que haviam desenvolvido penalizava mulheres; considerava a experiência de ser “capitã de um time feminino de xadrez” negativa, por conter o termo “feminino”, assim como descreditava a candidata se ela houvesse se formado em uma instituição de ensino exclusivamente feminina. Para complementar, incentivava a presença de termos mais frequentemente

usados por homens (Dastin, 2018).

Isso aconteceu por que os dados que tinham de “bons currículos” provinham da força de trabalho da própria Amazon, majoritariamente masculina. Por isso, o algoritmo aprendeu e internalizou a disparidade de gênero, e aplicou-a para os novos candidatos à qual foi apresentado. Mesmo que “gênero” não fosse, explicitamente, um parâmetro dado ao algoritmo, ele assimilou-o, reconstruindo-o a partir de outros dados (como, nesse caso, as expressões utilizadas). Ou, como Hooker (2021, tradução própria) coloca,

Para domínios como imagens, linguagem e vídeo, a alta dimensionalidade do problema e o tamanho maior do conjunto de dados modernos torna difícil garantir que todas as características são sistematicamente rotuladas. Mesmo se podemos rotular, em escala, atributos sensíveis como gênero e raça, algoritmos ainda podem usar variáveis *proxy* para reconstruir o rótulo proibido. Coleta de mesmo um número limitado de atributos protegidos pode ser oneroso. Por exemplo, é difícil alinhar-se em uma taxonomia padrão – categorias atribuídas à raça ou gênero são frequentemente codificadas de maneiras inconsistentes entre conjuntos de dados. Ademais, adquirir rótulos para os atributos protegidos legalmente é comumente percebido como intrusivo, levando a rótulos com ruído ou incompletos.⁵

Num caso simples, seria possível tratar os dados – “desenviesá-los”. Se tratando de textos (como um currículo), porém, essa tarefa é ainda mais difícil: seria possível “desgenerizar” um texto, sem retirar a essência da expressão pessoal ali contida? Assepsiá-lo, anonimizá-lo, removendo assim a possibilidade de qualquer viés – não só de gênero – ser identificado pelo algoritmo? A resposta é um contundente não: como Hooker diz, é difícil garantir que “todas as categorias foram sistematicamente rotuladas”, ou seja, mesmo que fosse possível identificá-las, a alta complexidade e dimensionalidade (isto é, presença de muitas variáveis diferentes para uma mesma observação) do problema asseguram que tal identificação será falha. Isso, sem contar que as tais “categorias sensíveis”, que deveriam ser eliminadas para garantir a total neutralidade – gênero, raça, etnia, origem, posicionamento político – são intrínsecas ao sujeito, e, mesmo que inconscientemente, afluem na sua produção. Um algoritmo suficientemente sensível pode (e muito provavelmente vai, se treinado com tempo e recursos suficientes) identificar mínimas sutilezas, mesmo que invisíveis para um ser humano.

Suponha então que, nesse caso da Amazon, uma candidata fosse reprovada pelo algoritmo de triagem de currículos, e, desconfiada, exigisse uma explicação para o porquê do algoritmo ter dado tal resultado. Seria possível obter isso? Esse algoritmo precisa interpretar textos, o que não é uma tarefa simples, requerendo um modelo mais complexo do que, por exemplo,

⁵Traduzido do inglês. Original: “For domains such as images, language, and video, the high dimensionality of the problem and large size of modern datasets make it hard to guarantee all features are comprehensively labeled. Even if we are able to label sensitive attributes at scale such as gender and race, algorithms can still leverage proxy variables to reconstruct the forbidden label. Data collection of even a limited number of protected attributes can be onerous. For example, it is hard to align on a standard taxonomy—categories attributed to race or gender are frequently encoded in inconsistent ways across datasets. Furthermore, procuring labels for these legally protected attributes is often perceived as intrusive leading to noisy or incomplete labels.” (Hooker, 2021)

uma regressão linear. Um modelo mais complexo, como já foi dito, implica em uma maior quantidade de pesos/parâmetros, e, por isso, menor significância de cada parâmetro individualmente. Com parâmetros menos significantes, dificulta-se a compreensão do raciocínio realizado, precisamente porque esse “raciocínio” não é nada equivalente a um pensamento orgânico; mas sim, uma aproximação de um fenômeno, que não tem nada de racional ou lógica.

Máquinas não pensam: elas seguem ordens. Para simular o pensamento, são usados milhões de parâmetros, que podem ter um resultado parecido com um raciocínio, mas não passa de um conjunto de parâmetros matemáticos. *Quanto mais complexo é o fenômeno, maior deverá ser o modelo, e menos sentido ele fará.* A suposta candidata rejeitada poderia até ter acesso ao modelo inteiro, com todos seus milhares de números, e não conseguiria tirar nenhuma informação disso. O sistema é uma “caixa-preta”: pode ser compreendido em termos de suas entradas e saídas, mas seu funcionamento interno é um mistério; por isso, não se pode pedir uma explicação (que está relacionada ao funcionamento interno), mas é possível perceber que o modelo está sendo sexista (pois suas saídas estão tortas).

Não ser capaz de fornecer explicações pode ser muito danoso, principalmente em casos mais sensíveis, como *scores* de cartão de crédito e prisões preventivas (ambos já documentados na literatura, como cita a introdução de Aïvodji *et al.* (2019)). Por isso, surge a ideia de criar outro modelo para explicar o inexplicável, e tentar aproximar o raciocínio de um modelo caixa-preta original, tendo como saída algo que seres humanos possam compreender. Isso pode acontecer de duas maneiras: ou explicando o modelo, ou explicando o resultado de uma predição. No primeiro caso, para um modelo b , deve se encontrar uma relação $g(b) \in \mathcal{E}$, onde $\mathcal{E}$ é o conjunto de todas as explicações possíveis e g é o modelo explicador que se deseja. No segundo caso, para um modelo b e uma instância x onde o modelo b foi usado, deve se encontrar $g(b, x) \in \mathcal{E}$, onde $\mathcal{E}$ permanece igual ao anterior, mas g passa a explicar b não em sua totalidade, mas sim para o caso x . Assim, se o modelo original tiver raciocínios diferentes para casos muito diferentes, o segundo caso é melhor; seria algo parecido que poderia ser usado com a candidata hipotética a um emprego da Amazon.

Uma questão que permanece é a forma de (E) . Uma possibilidade é que seja o conjunto de todas as funções lineares, que, como já foi visto na seção 2.1, tem só dois parâmetros (inclinação, que se chamou de β_1 , e altura, que se chamou de β_0), e por isso, é facilmente compreensível. Outras maneiras de fornecer explicações são árvores de decisões (basicamente, fluxogramas) e listas de regras (no estilo “se isso, então aquilo”). São, necessariamente, simplificações, construídas em torno do modelo original. Uma maneira de aproximar a aproximação ao raciocínio orgânico.

Parece uma boa ideia, até que se leva em conta que g pode mentir, num processo que Aïvodji *et al.* (2019) chama de “fairwashing” – em português, “lavagem da verdade”. Se uma empresa desejar ser deliberadamente sexista, mas temer ser confrontada, poderia produzir um modelo b enviesado, e fabricar g de modo a fornecer uma explicação, “passando pano” no viés de b , de modo que o modelo torna-se racionalizado, mesmo que falsamente. No *paper* supracitado,

os autores não só teorizam, como fabricam um modelo capaz de realizar isso.

Além da possibilidade de um viés nos dados, há também a possibilidade de um viés no modelo: [racismo em CV]

2.4 Natureza

Referências

AÏVODJI, Ulrich *et al.* **Fairwashing: The Risk of Rationalization**. 15 maio 2019. DOI: 10.48550/arXiv.1901.09749. arXiv: 1901.09749. Disponível em: <http://arxiv.org/abs/1901.09749>. Pré-publicado.

ASADU, Chinedu. **Nigeria Fines Meta \$220 Million for Violating Data Protection and Consumer Rights Laws**. AP News. 19 jul. 2024. Disponível em: <https://apnews.com/article/nigeria-meta-fine-facebook-whatsapp-9c79447e348dcaaa1b8c59898e60c7fa>. Acesso em: 5 jun. 2025.

BARRON, Laignee. **Could Facebook Have Stopped the Spread of Hate in Myanmar?** TIME. 6 abr. 2018. Disponível em: <https://time.com/5230474/facebook-myanmar-hate-speech-rohingya/>. Acesso em: 9 ago. 2025.

BASHIR, Muhammad Admad. **On the Privacy Implications of Real Time Bidding**. 2019. Northeastern University. DOI: 10.17760/D20321280. HDL: 2047/D20321280. Disponível em: <http://hdl.handle.net/2047/D20321280>. Acesso em: 2 maio 2025.

BELENKIY, Ari; ECHAGUE, Eduardo Vila. **Groping Toward Linear Regression Analysis: Newton's Analysis of Hipparchus' Equinox Observations**. 4 fev. 2016. DOI: 10.48550/arXiv.0810.4948. arXiv: 0810.4948 [physics]. Disponível em: <http://arxiv.org/abs/0810.4948>. Acesso em: 20 ago. 2025. Pré-publicado.

BINDER, Matt. Republican Campaign Put Beacons on Lawn Signs to Track Phones, Company Says. **Mashable**, 24 out. 2019. Disponível em: <https://mashable.com/article/beacons-location-tracking-republican-campaign>. Acesso em: 2 maio 2025.

CADWALLADR, Carole; GRAHAM-HARRISON, Emma. 50 Million Facebook Profiles Harvested for Cambridge Analytica in Major Data Breach. **The Guardian: News**, 17 mar. 2018. ISSN 0261-3077. Disponível em: <https://www.theguardian.com/news/2018/mar/17/cambridge-analytica-facebook-influence-us-election>. Acesso em: 14 ago. 2025.

CHEN, Brian X. 'Fingerprinting' to Track Us Online Is on the Rise. Here's What to Do. **The New York Times: Technology**, Nova York, 3 jul. 2019. ISSN 0362-4331. Disponível em: <https://www.nytimes.com/2019/07/03/technology/personaltech/fingerprinting-track-devices-what-to-do.html>. Acesso em: 1 maio 2025.

CIREŞAN, Dan; MEIER, Ueli; SCHMIDHUBER, Juergen. **Multi-Column Deep Neural Networks for Image Classification**. 13 fev. 2012. DOI: 10.48550/arXiv.1202.2745. arXiv: 1202.2745 [cs]. Disponível em: <http://arxiv.org/abs/1202.2745>. Acesso em: 21 ago. 2025. Pré-publicado.

COUTTS, Sharona. Anti-Choice Groups Use Smartphone Surveillance to Target ‘Abortion-Minded Women’ During Clinic Visits. **Rewire News Group**, 25 maio 2016. Disponível em: <https://rewirenewsgroup.com/2016/05/25/anti-choice-groups-deploy-smartphone-surveillance-target-abortion-minded-women-clinic-visits/>. Acesso em: 1 maio 2025.

CYPHERS, Bennet; GEBHART, Gennie. **Behind the One-Way Mirror: A Deep Dive Into the Technology of Corporate Surveillance**. [S. l.], 2 dez. 2019. Disponível em: <https://www.eff.org/wp/behind-the-one-way-mirror>. Acesso em: 16 maio 2025.

DASTIN, Jeffrey. **Amazon Scraps Secret AI Recruiting Tool That Showed Bias against Women**. Reuters. 11 out. 2018. Disponível em: <https://www.reuters.com/article/world/insight-amazon-scraps-secret-ai-recruiting-tool-that-showed-bias-against-women-idUSKCN1MK0AG/>. Acesso em: 26 ago. 2025.

DE SOUZA, Sérgio. **Treinamento de guerra: Fiz as oficinas do Google e da Meta no seminário do partido do Bolsonaro**. Intercept Brasil. 4 jun. 2025. Disponível em: <https://www.intercept.com.br/2025/06/04/oficinas-google-meta-partido-bolsonaro/>. Acesso em: 5 jun. 2025.

DE TOLEDO, José Roberto. **PL 2630: Lobby descarado mostra poder ilimitado de big techs como Google**. UOL. 2 maio 2023. Disponível em: <https://noticias.uol.com.br/colunas/jose-roberto-de-toledo/2023/05/02/pl-2630-lobby-decarado-mostra-poder-ilimitado-de-big-techs-como-google.htm>. Acesso em: 5 jun. 2025.

GIRISH, Aniketh *et al.* **Disclosure: Covert Web-to-App Tracking via Localhost on Android**. Local Mess. 2025. Disponível em: <https://localmess.github.io>. Acesso em: 5 jun. 2025.

HAN, Byung-Chul. **Infocracia: Digitalização e a crise da democracia**. Tradução: Gabriel S. Philipson. Petrópolis, RJ: Editora Vozes, 4 mar. 2022. 104 p. ISBN 978-65-5713-566-2.

HILL, Kashmir. Automakers Are Sharing Consumers’ Driving Behavior With Insurance Companies. **The New York Times: Technology**, 11 mar. 2024. ISSN 0362-4331. Disponível em: <https://www.nytimes.com/2024/03/11/technology/carmakers-driver-tracking-insurance.html>. Acesso em: 18 maio 2025.

HOOKE, Sara. Moving beyond “Algorithmic Bias Is a Data Problem”. **Patterns**, v. 2, n. 4, p. 100241, abr. 2021. ISSN 26663899. DOI: 10.1016/j.patter.2021.100241. Disponível em: <https://linkinghub.elsevier.com/retrieve/pii/S2666389921000611>. Acesso em: 31 jan. 2025.

INTERNET ARCHIVE. **Petabox**. Disponível em: <https://archive.org/web/petabox>. Acesso em: 8 jun. 2025.

JAMES, Gareth *et al.* **An Introduction to Statistical Learning: With Applications in R**. New York, NY: Springer US, 2021. (Springer Texts in Statistics). ISBN 978-1-0716-1417-4 978-1-0716-1418-1. DOI: 10.1007/978-1-0716-1418-1. Disponível em: <https://link.springer.com/10.1007/978-1-0716-1418-1>. Acesso em: 9 ago. 2025.

KELION, Leo. Spy Pixels in Emails Have Become Endemic. **BBC**, Londres, 17 fev. 2021. Disponível em: <https://www.bbc.com/news/technology-56071437>. Acesso em: 16 maio 2025.

LECUN, Yann; CORTES, Corinna; BURGESS, Christopher J. C. **MNIST Handwritten Digit Database, Yann LeCun, Corinna Cortes and Chris Burges**. 1998. Disponível em: <https://yann.lecun.org/exdb/mnist/index.html>. Acesso em: 21 ago. 2025.

MACKEY, Aaron. **EFF Sues AT&T, Data Aggregators For Giving Bounty Hunters and Other Third Parties Access to Customers’ Real-Time Locations**. [S. l.], 16 jul. 2019. Disponível em: <https://www.eff.org/press/releases/eff-sues-att-data-aggregators-giving-bounty-hunters-and-other-third-parties-access>. Acesso em: 1 maio 2025.

MCKINSEY. **Monetizing Car Data**. [S. l.], set. 2016. Disponível em: <https://www.mckinsey.com/industries/automotive-and-assembly/our-insights/monetizing-car-data>. Acesso em: 2 maio 2025.

MEJIAS, Ulises Ali; COULDRY, Nick. **Data Grab: The New Colonialism of Big Tech and How to Fight Back**. Chicago: The University of Chicago Press, 2024. ISBN 978-0-226-83230-2.

MELLO, Patrícia C. Google contrata Temer para atuar nas negociações sobre regulação de big techs. **Folha de S. Paulo: Poder**, São Paulo, 30 jun. 2023. Disponível em: <https://www1.folha.uol.com.br/poder/2023/06/google-contrata-temer-para-atuar-nas-negociacoes-sobre-regulacao-de-big-techs.shtml>. Acesso em: 5 jun. 2025.

MOROZOV, Evgeny. **Big Tech**. São Paulo: Ubu Editora, 25 out. 2018. ISBN 978-85-7126-012-2.

MOROZOV, Evgeny; DENVIR, Daniel. **Não, não é tecnofeudalismo. Ainda é capitalismo**. Tradução: Taís Hoshika. Jacobin Brasil. 23 jun. 2023. Disponível em: <https://jacobin.com.br/2023/06/nao-nao-e-tecnofeudalismo-ainda-e-capitalismo/>. Acesso em: 8 jun. 2025.

OHM, Paul. Broken Promises of Privacy: Responding to the Surprising Failure of Anonymization. **UCLA Law Review**, v. 57, p. 1701, 13 ago. 2009. Disponível em: <https://ssrn.com/abstract=1450006>. Acesso em: 1 maio 2025.

PNAD CONTÍNUA. **Acesso à internet e à televisão e posse de telefone móvel celular para uso pessoal 2023**. Edição: Coordenação de Pesquisas por Amostra de Domicílios. Rio de Janeiro, RJ: IBGE, 9 set. 2024. 17 p. ISBN 978-85-240-4622-3.

SCHURIG, Sofia; ALMEIDA, Rodolfo. **De quem são os projetos de lei sobre IA na Câmara**. Núcleo Jornalismo. 8 nov. 2024. Disponível em: <https://nucleo.jor.br/especiais/2024-11-08-projetos-lei-ia-congresso/>. Acesso em: 2 maio 2025.

SCHURIG, Sofia; GRANJEIA, Julianna. **Como conflitos entre ministérios e Big Tech moldaram a proposta de regulação de IA no Senado**. Núcleo Jornalismo. 11 dez. 2024. Disponível em: <https://nucleo.jor.br/reportagem/2024-12-11-conflito-entre-ministerios-e-lobby-da-industria-alteram-proposta-de-regulacao-de-ia/>. Acesso em: 2 maio 2025.

SCHURIG, Sofia; SPAGNUOLO, Sérgio. **Meta colocou dados de crianças em risco para treinar IA, diz ANPD**. Núcleo Jornalismo. 2 jul. 2024. Disponível em: <https://nucleo.jor.br/reportagem/2024-07-02-meta-colocou-dados-de-brasileiros-em-risco-para-treinar-ia/>. Acesso em: 18 maio 2025.

SOLTANI, Ashkan. **Privacy Trade-Offs in Retail Tracking**. Federal Trade Commission. 30 abr. 2015. Disponível em: <https://www.ftc.gov/policy/advocacy-research/tech-at-ftc/2015/04/privacy-trade-offs-retail-tracking>. Acesso em: 2 maio 2025.

SOPRANA, Paula; AMÂNCIO, Thiago. ViaQuatro é condenada por reconhecimento facial sem autorização no Metrô de SP. **Folha de S. Paulo**, São Paulo, 11 maio 2021. Disponível em: <https://www1.folha.uol.com.br/cotidiano/2021/05/viaquatro-e-condenada-por-reconhecimento-facil-sem-autorizacao-no-metro-de-sp.shtml>. Acesso em: 1 jun. 2025.

SPAGNUOLO, Sérgio. **O lobby das Big Techs venceu no Brasil**. Núcleo Jornalismo. 11 jul. 2024. Disponível em: <https://nucleo.jor.br/raiox/2024-07-11-lobby-big-techs-venceu-brasil/>. Acesso em: 5 jun. 2025.

SY, Erik *et al.* Tracking Users across the Web via TLS Session Resumption. **Proceedings of the 34th Annual Computer Security Applications Conference**, p. 289–299, 3 dez. 2018. DOI: 10.1145/3274694.3274708. Disponível em: <https://dl.acm.org/doi/10.1145/3274694.3274708>. Acesso em: 1 maio 2025.

TEIXEIRA, Pedro S. Meta Espionou Histórico de Internet de Celulares Android, Burlando Guia Anônima e VPN, Diz Estudo. **Folha de S. Paulo**, São Paulo, 4 jun. 2025. Disponível em: <https://www1.folha.uol.com.br/tec/2025/06/meta-espionou-historico-de-internet-de-celulares-android-burlando-guia-anonima-e-vpn-diz-estudo.shtml>. Acesso em: 5 jun. 2025.

VAROUFAKIS, Yanis. O tecnofeudalismo está dominando. Tradução: Gercyane Oliveira. **Jacobin Brasil**, 22 nov. 2023. Disponível em: <https://jacobin.com.br/2023/11/o-tecno-feudalismo-esta-dominando/>. Acesso em: 8 jun. 2025.

VOPSON, Melvin M. The Information Catastrophe. **AIP Advances**, v. 10, n. 8, p. 085014, 1 ago. 2020. ISSN 2158-3226. DOI: 10.1063/5.0019941. Disponível em: <https://pubs.aip.org/adv/article/10/8/085014/990263/The-information-catastrophe>. Acesso em: 3 maio 2025.

YOUYOU, Wu; KOSINSKI, Michal; STILLWELL, David. Computer-Based Personality Judgments Are More Accurate than Those Made by Humans. **Proceedings of the National Academy of Sciences**, v. 112, n. 4, p. 1036–1040, 27 jan. 2015. ISSN 0027-8424, 1091-6490. DOI: 10.1073/pnas.1418680112. Disponível em: <https://pnas.org/doi/full/10.1073/pnas.1418680112>.