

Colégio Ítaca

Francisco Pessoa

Por que privacidade?
A proteção de dados pessoais num mundo conectado

Professor Orientador
João Homero do Amaral

São Paulo
2025

Sumário

Lista de Figuras	2
1 A alma das máquinas: como pode um algoritmo pensar?	3
1.1 Retas e curvas	4
1.2 Imitando o cérebro	7
1.3 Colocando a máquina na rua	12
1.4 O homem e a câmera	14
Referências	18

Lista de Figuras

1.1	Gráfico da anomalia (°C) em função do tempo (anos), 1970-2025	4
1.2	Gráfico da anomalia (°C) em função do tempo (anos), 1970-2025, com modelo de regressão linear	6
1.3	Gráfico da anomalia (°C) em função do tempo (anos), 1970-2025, com regressão linear e polinomial	7
1.4	Algumas imagens do banco de dados MNIST	8
1.5	Arquitetura de uma rede neural básica	10
1.6	Algumas funções de ativação comuns.	11

Capítulo 1

A alma das máquinas: como pode um algoritmo pensar?

*Chega mais perto e contempla as palavras.
Cada uma
tem mil faces secretas sob a face neutra
e te pergunta, sem interesse pela resposta,
pobre ou terrível, que lhe deres:
Trouxeste a chave?*

— Carlos Drummond de Andrade, “A Procura da Poesia”

É difícil ver o noticiário hoje sem se deparar com as Inteligências Artificiais (IAs). Contudo, entre o uso de ChatGPT para trabalhos escolares, trabalhadores preocupados com perder o emprego para uma máquina, e até alguns com medo da humanidade ser inteiramente aniquilada num apocalipse da era digital, o uso de IAs é tão mais comum quanto mais dissimulado.

A culpa disso é do fato que “Inteligência Artificial” está muito mais próximo de uma expressão de marketing feita para atrair a atenção do que de um termo técnico. Ela pressupõe uma semelhança entre o pensamento orgânico, tal como humanos o fazem, e um suposto pensamento sintético que, como há de ser visto nesse capítulo, é inteiramente dessemelhante a seu equivalente vivo.

Por trás da Inteligência Artificial há um conjunto de técnicas estatísticas e computacionais que fazem o chamado *aprendizado de máquina* ou *aprendizado estatístico*. Antes de entender *como* um computador pode aprender, é necessário responder *por que* se quer que ele aprenda. Há muito que um computador pode fazer sem a necessidade desse treinamento: isso inclui fazer contas, navegar pela Internet, assistir a um filme, tipografar uma monografia, entre outros. Então, o que diferencia essas atividades de uma Inteligência Artificial?

A resposta é que essas atividades podem ser (e são) descritas por meio de código, o que requer representá-las como um conjunto de instruções claras e objetivas: uma receita de como as realizar. É fácil elaborar uma receita de como reproduzir um vídeo, por exemplo. O computador deverá localizar o arquivo que contém o vídeo, abri-lo, decodificá-lo e reproduzi-lo, convertendo as informações numéricas para cores a uma determinada taxa de vezes por segundo.


Por mais que cada passo aqui descrito possa ser desmembrado em tantos outros mais, qualquer programa de computador é descritível como um conjunto de instruções. Todo processador é construído aos moldes de uma Arquitetura de Conjunto de Instruções (ISA, do inglês *Instruction Set Architecture*), um modelo abstrato que delimita, simplificadamente, como se pode programá-lo. Um dos componentes disso é um conjunto de instruções que o processador pode executar, para o qual *todos* os programas que são usados devem ser reduzidos. Essas instruções são coisas simples, como “coloque tal valor em tal lugar”, “some tal valor com tal valor” e “faça isso se tal valor for verdadeiro”.

É possível criar uma “receita para escrever”? Ou uma “receita para recomendar vídeos”? Isto é, um conjunto de instruções objetivas que permita realizar essas ações? Não. E é aqui que entra o uso de uma IA: aproximar objetivamente processos que não podem ser descritos assim.

1.1 Retas e curvas

Observe o seguinte gráfico com o valor da anomalia da temperatura média do globo terrestre em relação à média do século XX, entre 1970 e 2025, retirado de NOAA National Centers for Environmental Information (2025), órgão do governo dos Estados Unidos:

Figura 1.1: Gráfico da anomalia ($^{\circ}\text{C}$) em função do tempo (anos), 1970-2025



Empiricamente, é possível perceber que existe uma tendência nesses dados, que seguem aproximadamente uma reta. Porém, é difícil determinar precisamente de quanto é essa tendência, e para onde o gráfico continuará. Isso se deve ao fato de que o planeta Terra é um sistema complexo: ele não segue uma ordem do tipo “aumente $0,5^{\circ}\text{C}$ ao ano”. Na metáfora da seção anterior, é impossível estabelecer uma receita para a temperatura do planeta em função do ano.

Pode-se, contudo, aproximá-la. Sabe-se, a partir desses dados, como o modelo deve se

comportar. Não é possível, principalmente quando se trata de algo tão simples como uma reta, que ele abarque cada mínima mudança e inconsistência; é, afinal, uma aproximação.

Qual deverá ser a forma desse modelo? Matematicamente, uma reta pode ser definida por meio de uma função linear, que, nesse caso, assumiria a forma de

$$A(t) = t \cdot \beta_1 + \beta_0 \quad (1.1)$$

Isto é, a anomalia A , em função do tempo t , pode ser definida como o tempo t multiplicado por um coeficiente β_1 somado a um coeficiente estático β_0 . Assim, para determinar a anomalia, t deve ser transformado, segundo os parâmetros β_0 e β_1 que, até agora, *não se sabe quais são*. Intuitivamente, β_1 é a inclinação da reta, e β_0 está relacionado com a altura dela, ou sua posição vertical. A grande pergunta, portanto, é quais são esses coeficientes, ou seja, como t deve ser mudado para obter A .

Para determinar esses dois coeficientes, β_0 e β_1 , é necessário primeiro conceber uma maneira de comparar dois modelos, e descobrir qual deles mais se aproxima do fenômeno aproximado. Uma maneira muito simples de fazer isso é, para cada ano, contabilizar a distância entre o valor previsto pelo modelo e a observação real. O objetivo da criação do modelo, assim, passa a ser reduzir ao máximo possível esse erro. Comumente, ao invés de simplesmente usar o erro, é considerado o erro elevado ao quadrado; assim, erros menores são menos penalizados, e erros maiores serão ainda mais penalizados, pois seu valor crescerá com mais rapidez. Essa abordagem é chamada de “mínimos quadrados”, pois almeja minimizar os quadrados dos erros (James *et al.*, 2021).


O processo de descobrir β_0 e β_1 é conhecido como *aprendizado* ou *treinamento*. Ele envolve inicializar esses valores com um “chute”, e, gradualmente, melhorá-los. Para isso, muda-se ou β_0 ou β_1 , incrementando-o por pouco. Se a mudança for bem-vinda, ou seja, diminuir o erro, ela é mantida; caso contrário, o original é melhor. Ao repetir esse processo várias vezes, a reta será acomodada nos coeficientes com menor valor de erro.

No caso da figura 1.1, isso toma a forma da figura 1.2.

Antes, foi dito que β_1 representava a inclinação da reta. Além disso, ele cumpre outra função importante: representar a *taxa de variação* da reta; como a unidade de medida em questão é anos, isso significa quanto a temperatura vai variar por ano. A regressão realizada nesse conjunto de dados revela que a anomalia de temperatura média global cresce em um ritmo de $0,019^\circ C$ ao ano.

Perceptivelmente, essa anomalia vem crescendo mais nos últimos anos do que vinha anteriormente, devido às mudanças climáticas. O modelo de reta, por ter que simplificar drasticamente, é incapaz de expressar isso, de tal modo que nos últimos três anos sua estimativa está abaixo do valor real. Geralmente, o que importa não é o quão próximo o modelo está dos dados já existentes, mas sim o quão bem o modelo se dá com extrapolar esses dados e, literalmente, prever o futuro. Dadas essas tendências recentes, esse modelo pode não ser tão útil, uma vez

Figura 1.2: Gráfico da anomalia (°C) em função do tempo (anos), 1970-2025, com modelo de regressão linear



que não detêm a habilidade de contemplá-las suficientemente. Um modelo melhor, nesse caso, ao invés de uma reta usaria uma curva. Um exemplo está na figura 1.3.

Esse modelo não é mais linear, evidentemente. É, pelo contrário, uma curva definida por meio de um polinômio. Nesse caso, a representação matemática é de

$$A(t) = \beta_0 + t\beta_1 + t^2\beta_2 + t^3\beta_3 \dots t^n\beta_n \quad (1.2)$$


Em que n é o grau do polinômio a ser criado. Aqui, não se trata de uma regressão *linear*, mas sim, *polinomial* (James *et al.*, 2021).

Está além do escopo deste presente texto debater o funcionamento interno desses modelos (isto é, como efetivamente ocorre a regressão linear), mas é importante perceber que, quando se utiliza uma curva, ao invés de uma reta, o modelo torna-se mais flexível, podendo adaptar-se melhor às condições dos dados. Isto é, o erro do modelo é menor. Porém, funções desse tipo têm uma tendência a “explodir” atingindo valores escalafobéticos, para cima ou para baixo, tanto antes quanto depois dos dados. São piores do que os modelos lineares em questão de inferência de valores futuros e passados, portanto, mas são melhores em termos de adaptarem-se aos dados presentes.

Contudo, ao invés de dois parâmetros simples — β_0 e β_1 — agora há n , que não podem ser compreendidos de uma maneira tão direta quanto esses dois. Isto é, ganha-se flexibilidade, mas há uma perda de interpretabilidade. Na próxima seção, 1.2, será estudado um modelo ainda mais flexível; e ainda menos interpretável: as redes neurais. A seção 1.3 debaterá como essa “interpretabilidade” é refletida em um caso real: é possível pedir explicações desses modelos? Determinar porque algo foi classificado como bom ou ruim, A ou B?

O exemplo aqui apresentado parece simples, mas serve para definir um conceito importante, que será retomado múltiplas vezes: o *aprendizado de máquina*. Para um computador, aprender é diminuir uma função erro, por meio da alteração de um conjunto de parâmetros. O

Figura 1.3: Gráfico da anomalia (°C) em função do tempo (anos), 1970-2025, com regressão linear e polinomial



aprendizado requer dados; muitos dados; e aí entra o conteúdo do primeiro capítulo. Terminado o treinamento, o modelo vai poder, a partir dos dados coletados, realizar previsões, inferências, classificações, entre outros, acerca desses dados.

Regressões lineares são um dos algoritmos mais simples que demonstram a dinâmica completa do aprendizado de máquina; tanto é, que foi o primeiro desses algoritmos a ser estudado, com o método de mínimos quadrados tendo sido empregado por Isaac Newton para determinar a duração exata do ano (Belenkiy; Echague, 2016). Há diversas maneiras de melhorá-lo. Uma das mais simples é realizar a regressão em mais de uma variável; por exemplo, podemos estimar o preço de uma casa baseado no tamanho (em m²), o número de quartos, a distância do centro, o andar, e a idade da casa. O modelo se assemelharia à equação 1.3.

$$\text{Preço} = \beta_0 + \beta_1 \cdot (\text{Tamanho}) + \beta_2 \cdot (\text{Quartos}) + \beta_3 \cdot (\text{Distância}) + \beta_5 \cdot (\text{Andar}) + \beta_6 \cdot (\text{Idade}) \quad (1.3)$$

Em que $\beta_1, \beta_2, \beta_3, \beta_4, \beta_5$ e β_6 representam o quão significativos seus respectivos parâmetros são para o preço total do apartamento.


1.2 Imitando o cérebro

Por mais úteis que as regressões lineares possam ser, ainda são um modelo rudimentar, que trabalha com alguns pressupostos bastante restritivos. Um deles é o da linearidade da relação entre uma variável – como o ano, no caso da anomalia de temperatura, ou o andar, no caso do preço de apartamentos – e o resultado desejado. Assim, pressupõe-se que essa relação se dá por uma reta, e não, por exemplo, uma curva exponencial, logarítmica, ou qualquer outra coisa que

fuja da linearidade. Viu-se que isso pode ser consertado por meio de uma regressão polinomial¹. Contudo, há ainda um problema maior que a impede de ser utilizada em mais contextos: a possibilidade de relações entre variáveis. Para entender o que isso significa, considere outro exemplo: o banco de dados MNIST (LeCun; Cortes; Burges, 1998).

Ele é composto por milhares de imagens de dígitos de 0-9 desenhados à mão, assim como na figura 1.4. O objetivo que ele apresenta é fazer um modelo computacional capaz de identificar os dígitos baseando-se nas imagens apresentadas, semelhante ao que um ser humano faria ao ler esses números. Por mais que isso pareça simples, esse problema não o é – as imagens variam muito em sua forma, e a computação demorou para desenvolver métodos flexíveis o suficiente para essa tarefa.

Figura 1.4: Algumas imagens do banco de dados MNIST



O banco de dados MNIST foi publicado em 1998, e, segundo o próprio autor, o recorde é de 0,23% de erro, atingido em 2012, dentre os resultados publicados na literatura (Cireşan; Meier; Schmidhuber, 2012). As primeiras tentativas resultaram em taxas por volta dos 12% (LeCun; Cortes; Burges, 1998).

Essas imagens são na resolução de 28x28, ou seja, são constituídas de 28 linhas e 28 colunas de píxeis. Cada píxel pode assumir um valor em escala de cinza, representado como um número inteiro entre 0 (preto) e 255 (branco)². Isso significa que um modelo para prever o dígito escrito deve ter $28 \cdot 28 = 784$ entradas, e como saída, um número inteiro entre 0 e 9.

A complicação aqui apresentada é que, como cada um desses valores é uma variável, não se quer mais analisar a relação de uma única variável com a saída – é inútil saber quanto um único píxel influencia na saída –, mas sim, é necessário considerar um *conjunto* de variá-

¹A regressão polinomial está associada a muitos outros métodos que a acompanham. Para estendê-la para uma predição com base em múltiplas variáveis, como na equação 1.3, por exemplo, é possível usar um Método Aditivo Generalizado (GAM). Os GAMs criam uma função polinomial de grau n para cada variável, ou seja, uma função para o tamanho, uma para o número de quartos, uma para a distância do centro, e por aí vai. Assim, o modelo toma a cara de $\text{Preço} = \beta_0 + f_1(X_1) + f_2(X_2) + f_3(X_3) + \dots + f_i(X_i)$, onde $X_1 \dots X_i$ são as variáveis (como o andar e o número de quartos) e $f_1 \dots f_i$ são as funções de grau n que dependem de cada variável (James *et al.*, 2021)

²Se 255 parece um número arbitrário, lembre-se que ele é igual a $2^8 - 1$, o maior valor possível que pode ser guardado em oito bits

veis combinadas, como um traço ou uma curva. O modelo de regressões lineares, e mesmo as regressões polinomiais, não permitem isso, uma vez que tratam todas as variáveis de maneira independente.

Um dos métodos mais famosos para resolver tal problema são as redes neurais, que ganharam esse nome por seus componentes se assemelharem a neurônios. A arquitetura de uma rede neural básica está representada na figura 1.5 (James *et al.*, 2021).

Nesse modelo simples, há três camadas. A *camada de entrada* representa as variáveis sobre as quais se quer prever o resultado. Aqui, são três, E_1 , E_2 , e E_3 , mas outros modelos podem ser estruturados de modo a ter mais, ou menos. No caso do MNIST, é estritamente necessário que haja 784 nós de entrada, um para cada píxel da imagem.

No meio, temos uma *camada oculta*, que recebe esse nome, pois não é nem de entrada, nem de saída. Cada nó da camada oculta representa uma combinação de todos os nós da camada anterior, como se cada um deles fosse uma regressão linear feita na camada anterior. Por exemplo, o nó intermediário O_1 pode ser representado, a grosso modo, como:

$$O_1 = \beta_0 + \beta_1 \cdot E_1 + \beta_2 \cdot E_2 + \beta_3 \cdot E_3 \quad (1.4)$$

A *camada de saída* tem o mesmo princípio da camada oculta: cada nó dela é uma combinação de todos os nós da camada anterior (ou seja, os nós da camada oculta). A única diferença é que, no modelo já treinado, esses nós representam valores reais. Para o MNIST, isso geralmente é modelado como dez nós, cada um representando um dígito diferente, de modo que o valor computado de um nó seja equivalente à probabilidade (ou confiança), de que o algarismo certo seja aquele. Assim, o nó de maior valor será o dígito certo.

Contudo, o leitor astuto perceberá que nessa arquitetura é possível “simplificar” a rede neural, voltando a ser uma única função linear³. E isso é verdade. O pulo do gato, porém, é que a equação 1.4 só conta metade da história. A maneira certa de expressar o valor de um nó N em função de suas entradas (os nós da camada anterior que “apontam” para N) $I_1 \dots I_n$ é


$$N = \phi(\beta_0 + \beta_1 \cdot I_1 + \beta_2 \cdot I_2 + \dots + \beta_n \cdot I_n) \quad (1.5)$$

A única diferença da equação 1.5 para a equação 1.4 é a introdução de ϕ , uma função não-linear pré-determinada que atua como uma fonte de não linearidade para o modelo. Essa é a chamada *função de ativação*, e computa o valor de um nó da rede baseado em suas entradas e seus pesos (outro nome para os coeficientes que até agora foram chamados de β_n) (James *et al.*, 2021). Algumas funções de ativação comuns são a sigmoide, uma curva em forma de ‘S’:

$$\sigma(x) = \frac{1}{1 + e^{-kx}} \quad (1.6)$$

³Formalmente, a composição de várias funções lineares, que se dá por meio dos nós, ainda é uma função linear.

Figura 1.5: Arquitetura de uma rede neural básica



para uma dada constante k , e a retificadora linear ReLU:

$$\text{ReLU}(x) = \max(0, x) \quad (1.7)$$


A figura 1.6 mostra o comportamento delas.

A função dessas funções é introduzir a não-linearidade e, assim, permitir que se estabeleçam relações não-lineares entre as diversas entradas. Elas elevam a rede neural de uma simples “combinação de combinações lineares” para um modelo flexível capaz de expressar relações complexas.

Sendo assim, como se otimiza esses pesos? Com cálculo diferencial, principalmente. Computa-se um gradiente multidimensional que indica para onde vai o erro (aumentar ou diminuir) baseado em uma mudança num determinado parâmetro. Simplificadamente, para otimizar o parâmetro β_2 do nó X , “congela-se” o resto dos parâmetros e calcula-se o quanto o erro vai mudar baseado em uma mudança minúscula em β_2 . Na realidade, esse processo usa de vários métodos matemáticos, como diferenciação automática, descida de gradiente e retro-propagação. É muito elegante, mas foge ao escopo desse texto.

Uma rede neural têm muito mais parâmetros que uma regressão linear – como se havia dito, cada nó tem tantos pesos quanto entradas, e podem haver tantos nós quantos forem necessários. A arquitetura da imagem 1.5 é simplista também por representar somente uma camada oculta, quando na maioria dos casos se usam múltiplas, gerando ainda mais parâmetros. A expressão inglesa *Deep Learning* (aprendizado profundo) vem disso: uma rede neural é considerada profunda se tiver mais de uma camada oculta. Os grandes modelos de linguagem (LLMs) como o ChatGPT e o Deepseek, têm centenas de *bilhões* de parâmetros (DeepSeek-AI *et al.*, 2025). O problema com isso é que se torna basicamente impossível entender individualmente

Figura 1.6: Algumas funções de ativação comuns.



Em vermelho e azul, duas sigmóides com $k = 5$ e $k = 10$, respectivamente. Em verde, a ReLU.

o que um determinado parâmetro significa. A rede neural é sobretudo opaca, ininterpretável. Sendo ela uma aproximação dos dados, sabe-se que ela funciona, mas não *como* ela funciona, e, como uma aproximação, há sempre um erro.

Nessa miríade de métodos e funções, há muita margem para que um modelo que está certo (isto é, diminui a função erro ao máximo) errar: é possível, por exemplo, que haja demasiada precisão nas ínfimas características dos dados de treinamento, de modo que a taxa de erro diminui vertiginosamente (pois o modelo acompanha cada mínimo ruído dos dados) mas a capacidade de generalização se perde. Esse é um problema conhecido como *overfitting*. Ou também, é possível que o modelo entenda algum tipo de viés nos dados – como, por exemplo, haver mais dados de homens do que de mulheres – e enxergue uma relação disso com o resultado – por exemplo, achar que como mais brancos historicamente passam em vestibulares, logo brancos seriam mais capacitados para passar em vestibulares, tendo assim maior chance de aprovação. Um exemplo real desse problema será analisado na próxima seção, 1.3.

O leitor agora pode estar se perguntando por que os exemplos aqui utilizados não têm relação com o conteúdo do capítulo anterior. Afinal, para onde vão tantos dados coletados? A resposta é, para algoritmos muito parecidos com os apresentados, porém com quantidades de parâmetros e complexidade muito maiores. Um algoritmo de recomendação, por exemplo, tem de lidar com um fluxo enorme de dados concomitante. São tantos dados que esse segmento da indústria foi batizado de *Big Data* (literalmente, “Grande Dado”), concernindo os casos onde há uma vigilância tão presente, que produz uma massa de dados gigantesca; muito além do que pode ser tratado em um computador comum. Só os *Data Centers* especializados, que se estendem por múltiplos quilômetros quadrados e tem o consumo energético de cidades inteiras, podem manejar os tantos dados necessários para todos os múltiplos usuários simultâneos desses serviços. A era do Big Data é um tempo em que o conjunto de dados que um ser humano produz é alienado dele, passando para o uso quase livre das empresas de tecnologia que têm a

infraestrutura necessária para o processar: as assim chamadas “Big Techs”, ou grandes empresas de tecnologia.

1.3 Colocando a máquina na rua

Deixe os grandes algoritmos de lado; considere agora um pequeno exemplo com grandes implicações. Desde 2014, a Amazon vinha tentando filtrar computacionalmente os currículos a ela enviados. Em 2018, contudo, essa iniciativa foi posta abaixo em completo. O motivo? O algoritmo que haviam desenvolvido penalizava mulheres; considerava a experiência de ser “capitã de um time feminino de xadrez” negativa, por conter o termo “feminino”, assim como descreditava a candidata se ela houvesse se formado em uma instituição de ensino exclusivamente feminina. Para complementar, incentivava a presença de termos mais frequentemente usados por homens (Dastin, 2018).

Isso aconteceu por que os dados que tinham de “bons currículos” provinham da força de trabalho da própria Amazon, majoritariamente masculina. Por isso, o algoritmo aprendeu e internalizou a disparidade de gênero, e aplicou-a para os novos candidatos à qual foi apresentado. Mesmo que “gênero” não fosse, explicitamente, um parâmetro dado ao algoritmo, ele assimilou-o, reconstruindo-o a partir de outros dados (como, nesse caso, as expressões utilizadas). Ou, como Hooker (2021, tradução própria) coloca ⁴,

Para domínios como imagens, linguagem e vídeo, a alta dimensionalidade do problema e o tamanho maior do conjunto de dados modernos torna difícil garantir que todas as características são sistematicamente rotuladas. Mesmo se podemos rotular, em escala, atributos sensíveis como gênero e raça, algoritmos ainda podem usar variáveis *proxy* para reconstruir o rótulo proibido. Coleta de mesmo um número limitado de atributos protegidos pode ser oneroso. Por exemplo, é difícil alinhar-se em uma taxonomia padrão – categorias atribuídas à raça ou gênero são frequentemente codificadas de maneiras inconsistentes entre conjuntos de dados. Ademais, adquirir rótulos para os atributos protegidos legalmente é comumente percebido como intrusivo, levando a rótulos com ruído ou incompletos.

Num caso simples, seria possível tratar os dados – “desenviesá-los”. Se tratando de textos (como um currículo), porém, essa tarefa é ainda mais difícil: seria possível “desgengerizar” um texto, sem retirar a essência da expressão pessoal ali contida? Assepsiá-lo, anonimizá-lo,

⁴Traduzido do inglês. Original: “For domains such as images, language, and video, the high dimensionality of the problem and large size of modern datasets make it hard to guarantee all features are comprehensively labeled. Even if we are able to label sensitive attributes at scale such as gender and race, algorithms can still leverage proxy variables to reconstruct the forbidden label. Data collection of even a limited number of protected attributes can be onerous. For example, it is hard to align on a standard taxonomy—categories attributed to race or gender are frequently encoded in inconsistent ways across datasets. Furthermore, procuring labels for these legally protected attributes is often perceived as intrusive leading to noisy or incomplete labels.” (Hooker, 2021)

removendo assim a possibilidade de qualquer viés – não só de gênero – ser identificado pelo algoritmo? A resposta é um contundente não: como Hooker diz, é difícil garantir que “todas as categorias foram sistematicamente rotuladas”, ou seja, mesmo que fosse possível identificá-las, a alta complexidade e dimensionalidade (isto é, presença de muitas variáveis diferentes para uma mesma observação) do problema asseguram que tal identificação será falha. Isso, sem contar que as tais “categorias sensíveis”, que deveriam ser eliminadas para garantir a total neutralidade – gênero, raça, etnia, origem, posicionamento político – são intrínsecas ao sujeito, e, mesmo que inconscientemente, afluem na sua produção. Um algoritmo suficientemente sensível pode (e muito provavelmente vai, se treinado com tempo e recursos suficientes) identificar mínimas sutilezas, mesmo que invisíveis para um ser humano.

Suponha então que, nesse caso da Amazon, uma candidata fosse reprovada pelo algoritmo de triagem de currículos, e, desconfiada, exigisse uma explicação para o porquê do algoritmo ter dado tal resultado. Seria possível obter isso? Esse algoritmo precisa interpretar textos, o que não é uma tarefa simples, requerendo um modelo mais complexo do que, por exemplo, uma regressão linear. Um modelo mais complexo, como já foi dito, implica em uma maior quantidade de pesos/parâmetros, e, por isso, menor significância de cada parâmetro individualmente. Com parâmetros menos significantes, dificulta-se a compreensão do raciocínio realizado, precisamente porque esse “raciocínio” não é nada equivalente a um pensamento orgânico; mas sim, uma aproximação de um fenômeno, que não tem nada de racional ou lógica.

Máquinas não pensam: elas seguem ordens. Para simular o pensamento, são usados milhões de parâmetros, que podem ter um resultado parecido com um raciocínio, mas não passa de um conjunto de parâmetros matemáticos. *Quanto mais complexo é o fenômeno, maior deverá ser o modelo, e menos sentido ele fará.* A suposta candidata rejeitada poderia até ter acesso ao modelo inteiro, com todos seus milhares de números, e não conseguiria tirar nenhuma informação disso. O sistema é uma “caixa-preta”: pode ser compreendido em termos de suas entradas e saídas, mas seu funcionamento interno é um mistério; por isso, não se pode pedir uma explicação (que está relacionada ao funcionamento interno), mas é possível perceber que o modelo está sendo sexista (pois suas saídas estão tortas).

Não ser capaz de fornecer explicações pode ser muito danoso, principalmente em casos mais sensíveis, como *scores* de cartão de crédito e prisões preventivas (ambos já documentados na literatura, como cita a introdução de Aïvodji *et al.* (2019)). Por isso, surge a ideia de criar outro modelo para explicar o inexplicável, e tentar aproximar o raciocínio de um modelo caixa-preta original, tendo como saída algo que seres humanos possam compreender. Isso pode acontecer de duas maneiras: ou explicando o modelo, ou explicando o resultado de uma predição. No primeiro caso, para um modelo b , deve se encontrar uma relação $g(b) \in \epsilon$, onde ϵ é o conjunto de todas as explicações possíveis e g é o modelo explicador que se deseja. No segundo caso, para um modelo b e uma instância x onde o modelo b foi usado, deve se encontrar $g(b, x) \in \epsilon$, onde ϵ permanece igual ao anterior, mas g passa a explicar b não em sua totalidade, mas sim para o caso x . Assim, se o modelo original tiver raciocínios diferentes

para casos muito diferentes, o segundo caso é melhor; seria algo parecido que poderia ser usado com a candidata hipotética a um emprego da Amazon.

Uma questão que permanece é a forma de ϵ . Uma possibilidade é que seja o conjunto de todas as funções lineares, que, como já foi visto na seção 1.1, tem só dois parâmetros (inclinação, que se chamou de β_1 , e altura, que se chamou de β_0), e por isso, é facilmente compreensível. Outras maneiras de fornecer explicações são árvores de decisões (basicamente, fluxogramas) e listas de regras (no estilo “se isso, então aquilo”). São, necessariamente, simplificações, construídas em torno do modelo original, tentando se aproximar do raciocínio orgânico.

Parece uma boa ideia, até que se leva em conta que g pode mentir, num processo que Aïvodji *et al.* (2019) chama de “fairwashing” – em português, “lavagem da verdade”. Se uma empresa desejar ser deliberadamente sexista, mas temer ser confrontada, poderia produzir um modelo b enviesado, e fabricar g de modo a fornecer uma explicação, “passando pano” no viés de b , de modo que o modelo torna-se racionalizado, mesmo que falsamente. No *paper* supracitado, os autores não só teorizam, como fabricam um modelo capaz de realizar isso.

1.4 O homem e a câmera

Durante o curso desta monografia, foram apresentados diversos exemplos onde as estruturas sociais de vigilância têm, ou tiveram, consequências concretas. Contudo, talvez nenhum caso seja mais emblemático nesse aspecto do que o uso de câmeras equipadas com reconhecimento facial como método de segurança pública. Segundo levantamento do Projeto Panóptico, dirigido pelo Centro de Estudos de Segurança e Cidadania, há 442 projetos do tipo em curso, espalhados por todo o Brasil. No total, mais de 80 milhões de pessoas são potencialmente vigiadas (Centro de Estudos de Segurança e Cidadania, 2025). Um dos projetos mais emblemáticos dessa categoria é o Smart Sampa, da Prefeitura de São Paulo, que planeja integrar 40 mil câmeras a seu sistema até o final de 2025. Entre as câmeras já instaladas e em funcionamento, cerca de 12 mil pertencem a empresas privadas de segurança (Palhares; Machado, 2025).

Em sistemas como esses, a fonte de dados é o corpo humano, que, observado à distância, terá sua imagem convertida em uma representação digital. Ou como Dubbeld (2003, p. 160, tradução própria) coloca,⁵

⁵Original: “Initially, the body constitutes the prime focus of the camera gaze, and as such it is of major importance with respect to the initiation and application of camera surveillance – at their most basic level, cameras observe physical bodies, bodily appearances and distinct bodily features. Subsequently, when the body is registered through the camera mediated vision, the physical manifestation disappears to be replaced by or translated into the digital abstractions and representations of its outside appearances in camera systems (and linked ICTs, such as databases). The physical body as such appears to be of no value in this process: the digital data abstracted from it make up the source of information that is deemed valuable, and the embodied actor itself is in no way directly confronted. The body eventually comes back in to focus again, however, when the judgements based on its electronic representation have palpable consequences for the behaviours, perceptions and protections of data subjects. Even though camera surveillance represents individuals as virtual electronic data constructs, concrete consequences for the material embodied actor and the spaces it moves through may follow as well.”

Inicialmente, o corpo constitui o foco primário do olhar da câmera, e como tal ele é de importância maior no que diz respeito a iniciação e aplicação da vigilância por câmera – em seu nível mais básico, câmeras observam corpos físicos, aparências corporais e características corporais distintas. Subsequentemente, quando o corpo é registrado por meio da visão mediada pela câmera, a manifestação física desaparece, sendo substituída por ou traduzida em abstrações digitais e representações de sua aparência exteriores nos sistemas de câmera (e tecnologias da informação associadas, como bases de dados). O corpo físico como tal parece não ter valor nesse processo: os dados digitais abstraídos a partir deles que constituem a fonte da informação dita valiosa, e o ator encarnado em si não é, de nenhuma maneira, confrontado. O corpo, eventualmente, volta a ser o foco, de novo, quando os julgamentos baseados na sua representação eletrônica tem consequências palpáveis nos comportamentos, percepções, e proteções do sujeito dos dados. Embora a vigilância por câmeras represente indivíduos como construtos virtuais, eletrônicos, e de dados, consequências concretas para o ator encarnado material e os espaços pelos quais ele se move podem seguir.

Ou seja, o julgamento feito por um sistema como o Smart Sampa depende de uma tradução de uma observação do corpo físico para uma representação digital de caráter simbólico. Esse processo é realizado por meio de um algoritmo de aprendizado de máquina, que “aprendeu” a classificar e categorizar as imagens conforme uma configuração pré-fornecida. O indivíduo, assim, perde a sua individualidade, tornando-se – aos olhos da câmera – só mais um num imenso fluxo de dados. Dubbled também entende que, quando mais compreensivo é o sistema de vigilância, perde-se a capacidade de desaparecer; fundamentalmente, esses sistemas são uma maneira de localizar alguém nas movimentadas cidades modernas. A segurança pública passa a ser feito com uma representação do indivíduo convertida, formatada, replicável. É, sobretudo um sistema de julgamento baseado em aparências. O indivíduo, de certa forma, torna-se transparente.

A chamada Visão Computacional (CV, em inglês) aloca-se entre os algoritmos complexos, que, como foi visto antes sofrem de alguns problemas. Em primeiro, apesar de serem altamente flexíveis, ainda são aproximações: o Smart Sampa, em abril de 2025, mandou prender uma mulher grávida inocente, que, após sofrer agressão policial na abordagem, entrou em trabalho de parto prematuro e foi levada a uma unidade básica de saúde sob custódia (Audi, 2025).

Em segundo, esses algoritmos classificam e categorizam os indivíduos com base em determinadas categorias pré-estabelecidas que, geralmente, correspondem aos construtos sociais que já são usados para classificar pessoas, como gênero e raça. Ademais, podem assimilar outras variáveis sociais e econômicas a partir de vestimentas, comportamento, localização, entre outros. É, portanto, extremamente difícil evitar que tais sistemas adquiram vieses de gênero, raça, ou condição social – vieses esses que também se encontram incrustados em nossos sistemas jurídicos e policiais.

Por fim, essas categorias – gênero, raça, origem, condição social – são definidas, para um

sistema de vigilância, de forma *arbitrária*. Eles foram treinados sobre um conjunto de dados que continha milhares e milhares de casos rotulados do que *deve ser* um branco, um preto, uma mulher, e por aí vai. Essas classificações respondem aos interesses de quem as criou. Dubbeld (2003) também nota que muitas vezes esses sistemas são utilizados para rastrear e vigiar populações específicas ditas malfeitoras e marginais, que serão, portanto, mais fortemente policiadas. É difícil imaginar, em um país tão profundamente racista quanto o Brasil, que essas classificações de “perigo” não passem por uma concepção de raça, na visão da polícia. Khan e Fu (2021) analisam diversos conjuntos de dados relacionados a raça, e conclui que, “apesar de categorias raciais utilizadas entre conjuntos de dados serem superficialmente similares, a complexidade da percepção humana de raça sugere que os sistemas raciais codificados em um conjunto de dados podem ser substancialmente inconsistentes com outro” (Khan; Fu, 2021, p. 587, tradução própria)⁶.

Algoritmos de inteligência artificial são, sim, extremamente poderosos e tem amplo potencial de fazer o bem. Contudo, em uma sociedade que passa a se guiar cada vez mais a partir deles, seus problemas vêm à tona. Os algoritmos em si, claro, não tem culpa disso – são meras ferramentas projetadas por agentes sociais com intenções distintas – mas existem problemas estruturais com eles que guiam a formação de sociedade que eles produzem: a falta de transparência (isso é, não poder pedir explicações nem compreender o funcionamento dos modelos), a possibilidade de erros, a possibilidade de assimilação de vieses nos dados, ou a existência de um problema constitucional, na forma como o treinador escolheu e arquitetou o modelo. As bases da sociedade digital e plataformizada são sobretudo *frágeis*. E hoje, como mostra a última seção do primeiro capítulo, os próprios algoritmos fazem parte de estruturas de poder. Não são simples construções matemáticas, mas sim fatores determinantes na vida de pessoas e sociedades.

O maior agravante dessa situação é, como foi descrita no primeiro capítulo, a infraestrutura de vigilância que se construiu ao redor das pessoas. É justamente através das ditas inteligências artificiais que os dados, muitas vezes coletados e vendidos sem a ciência de seu sujeito, voltam para ele na forma de ações, recomendações, decisões, entre outros. Esse sistema tem como produto uma incessante digitalização da vida, não só em seus aspectos exteriores – trabalho, entretenimento, por exemplo – mas também uma digitalização do indivíduo, que passa a ser parcialmente regido por esses algoritmos falhos e problemáticos. Ademais, as entidades que controlam essa estrutura usufruem de uma centralização de dados, e, portanto, uma “centralização de individualidades”, uma extensa sabedoria da vida e obra de cada indivíduo. Por meio das inteligências artificiais, esse poder é concretizado, pois agora conseguem processar esses dados e transformá-los em coisas palpáveis. São grandes corporações como a Google, Microsoft, Amazon, entre outras, que capitaneiam esses processos.

Fica uma pergunta: é possível usar essa tecnologia para o bem? Não para o controle, nem para o lucro, mas sim para o benefício do povo? O próximo e último capítulo tentará responder

⁶Original: “Although the racial categories used across datasets are superficially similar, the complexity of human race perception suggests the racial system encoded by one dataset maybe substantially inconsistent with another.”

esse questionamento em duas vertentes: primeiro, por meio de uma análise de legislações regulatórias sendo postas em prática, como a Lei Geral de Proteção de Dados (LGPD) brasileira, e o Regulamento Geral de Proteção de Dados (GDPR, na sigla em inglês), da União Europeia. Segundo, pensando em uma alternativa ao modelo de lucro, falta de transparência, e concentração de poder, por meio do *software livre*, pautado na livre distribuição do código-fonte, total e irrestrita transparência, livre contribuição, e não-propriedade do código-fonte.

Referências

AÏVODJI, Ulrich *et al.* **Fairwashing: The Risk of Rationalization**. 15 maio 2019. arXiv: 1901.09749. Disponível em: <http://arxiv.org/abs/1901.09749>. Pré-publicado.

AUDI, Amanda. **Smart Sampa: Grávida é presa em posto de saúde e acaba tendo parto prematuro**. Agência Pública. 16 abr. 2025. Disponível em: <https://apublica.org/2025/04/smart-sampa-gravida-e-presa-em-posto-de-saude-e-acaba-tendo-parto-prematuro/>. Acesso em: 4 set. 2025.

BELENKIY, Ari; ECHAGUE, Eduardo Vila. **Groping Toward Linear Regression Analysis: Newton’s Analysis of Hipparchus’ Equinox Observations**. 4 fev. 2016. arXiv: 0810.4948. Disponível em: <http://arxiv.org/abs/0810.4948>. Acesso em: 20 ago. 2025. Pré-publicado.

CENTRO DE ESTUDOS DE SEGURANÇA E CIDADANIA. **O Panóptico - Monitor Do Reconhecimento Facial No Brasil**. Disponível em: <https://www.opanoptico.com.br/>. Acesso em: 4 set. 2025.

CIREŞAN, Dan; MEIER, Ueli; SCHMIDHUBER, Juergen. **Multi-Column Deep Neural Networks for Image Classification**. 13 fev. 2012. arXiv: 1202.2745 [cs]. Disponível em: <http://arxiv.org/abs/1202.2745>. Acesso em: 21 ago. 2025. Pré-publicado.

DASTIN, Jeffrey. **Amazon Scraps Secret AI Recruiting Tool That Showed Bias against Women**. Reuters. 11 out. 2018. Disponível em: <https://www.reuters.com/article/world/insight-amazon-scraps-secret-ai-recruiting-tool-that-showed-bias-against-women-idUSKCN1MK0AG/>. Acesso em: 26 ago. 2025.

DEEPSEEK-AI *et al.* **DeepSeek-V3 Technical Report**. 18 fev. 2025. arXiv: 2412.19437 [cs]. Disponível em: <http://arxiv.org/abs/2412.19437>. Acesso em: 8 set. 2025. Pré-publicado.

DUBBELD, Lynsey. Observing Bodies. Camera Surveillance and the Significance of the Body. **Ethics and Information Technology**, v. 5, n. 3, p. 151–162, 2003. ISSN 1388-1957. DOI: 10.1023/B:ETIN.0000006946.01426.26. Disponível em: <http://link.springer.com/10.1023/B:ETIN.0000006946.01426.26>. Acesso em: 30 mar. 2025.

HOOKE, Sara. Moving beyond “Algorithmic Bias Is a Data Problem”. **Patterns**, v. 2, n. 4, p. 100241, abr. 2021. ISSN 26663899. DOI: 10.1016/j.patter.2021.100241. Disponível em: <https://linkinghub.elsevier.com/retrieve/pii/S2666389921000611>. Acesso em: 31 jan. 2025.

JAMES, Gareth *et al.* **An Introduction to Statistical Learning: With Applications in R.** Nova York: Springer US, 2021. (Springer Texts in Statistics). ISBN 978-1-0716-1417-4 978-1-0716-1418-1. DOI: 10.1007/978-1-0716-1418-1. Disponível em: <https://link.springer.com/10.1007/978-1-0716-1418-1>. Acesso em: 9 ago. 2025.

KHAN, Zaid; FU, Yun. One Label, One Billion Faces: Usage and Consistency of Racial Categories in Computer Vision. *In: PROCEEDINGS of the 2021 ACM Conference on Fairness, Accountability, and Transparency*. Nova York: Association for Computing Machinery, 1 mar. 2021. (FAccT '21), p. 587–597. ISBN 978-1-4503-8309-7. DOI: 10.1145/3442188.3445920. Disponível em: <https://doi.org/10.1145/3442188.3445920>. Acesso em: 26 ago. 2025.

LECUN, Yann; CORTES, Corinna; BURGES, Cristopher J. C. **MNIST Handwritten Digit Database, Yann LeCun, Corinna Cortes and Chris Burges.** 1998. Disponível em: <https://yann.lecun.org/exdb/mnist/index.html>. Acesso em: 21 ago. 2025.

NOAA NATIONAL CENTERS FOR ENVIRONMENTAL INFORMATION. **Climate at a Glance: Global Time Series.** [S. l.: s. n.], ago. 2025. Disponível em: <https://www.ncei.noaa.gov/access/monitoring/climate-at-a-glance/global/time-series>. Acesso em: 6 set. 2025.

PALHARES, Fernanda; MACHADO, Giovanna. **Prefeitura de SP integra 5,3 mil câmeras ao Smart Sampa em parceria privada.** CNN Brasil. 30 ago. 2025. Disponível em: <https://www.cnnbrasil.com.br/nacional/sudeste/sp/prefeitura-de-sp-integra-53-mil-cameras-ao-smart-sampa-em-parceria-privada/>. Acesso em: 4 set. 2025.